Поиск по словам: индекс, BM25, метрики и границы

О. М. Атаева А. П. Халов

Осень 2026

Курс «От интеллектуального поиска к интеллектуальным агентам», ВМК МГУ. Модуль 2, занятие 1

Поиск сегодня: строка поиска везде

- Строка поиска стала интерфейсом по умолчанию: сайты, почта, документы, телефон, ассистент.
- Долгое время ответом на запрос были «десять синих ссылок»: ранжированный список документов, дальше человек читает сам.
- Большие языковые модели (ChatGPT, Claude, Gemini, Llama) изменили ожидания. Человек пишет вопрос обычным языком и ждёт ответа.



Шесть ожиданий от поиска сегодня.

Главное

Под каждым из шести ожиданий лежит один и тот же шаг: найти нужные документы и поставить их в правильном порядке. С этого шага начинается сегодняшнее занятие.

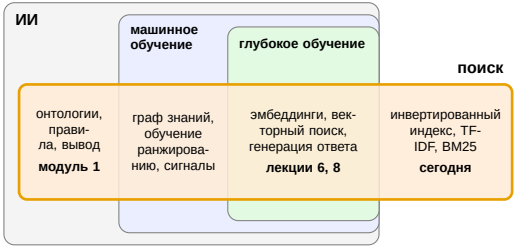
Что такое поиск на основе ИИ

Искусственный интеллект в разработке программ: программа решает задачу, для которой раньше нужен был человек. Сюда входят и системы на правилах.

Поиск: технология, которая по запросу находит информацию. В нём минимум два шага:

- **сопоставление**: какие документы подходят к запросу;
- **ранжирование**: в каком порядке их показать.

Поиск на основе ИИ: пересечение поиска с ИИ, машинным обучением и глубоким обучением.



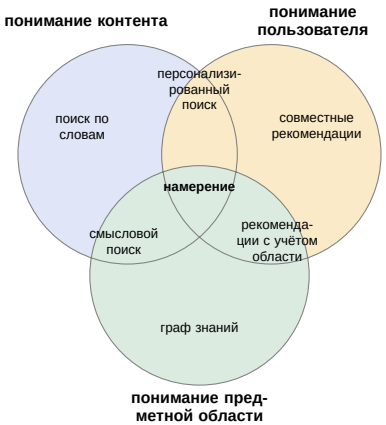
Оранжевая полоса есть поиск. Слева направо: методы ИИ без обучения, машинное обучение, глубокое обучение, классический поиск.

Главное

Классический поиск по словам лежит вне ИИ и служит основой для всего остального на этой картинке.

Модуль 1 работал в левой части полосы, модуль 2 идёт по ней справа налево.

Намерение пользователя: три понимания



Чтобы понять, что человек ищет, система соединяет три знания:

- **контент**: что написано в документах, какие слова совпали;
- **пользователь**: что искал раньше, что выбрал;
- **предметная область**: какие сущности и связи стоят за словами.

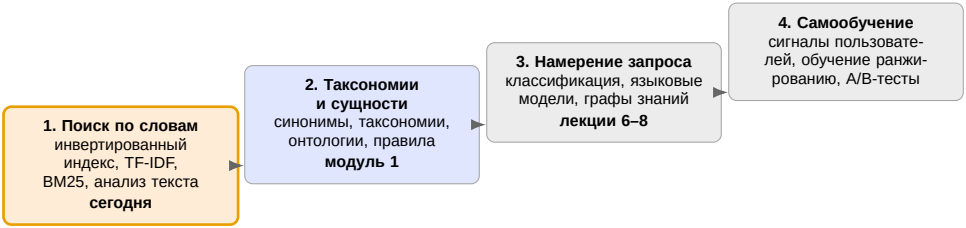
Поиск и рекомендации суть два конца одного спектра персонализации: от поиска по словам до рекомендаций без запроса.

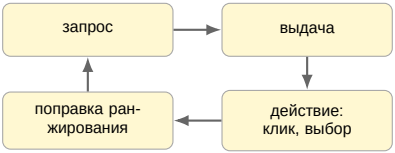
Курс идёт по двум кругам: контент (лекции 5–6) и предметная область (модуль 1, лекция 7). Понимание пользователя требует журналов поведения и в курс не входит.

Главное

Сегодня работаем в верхнем левом круге: поиск по словам. Пересечения с другими кругами появятся вместе с векторами и графом.

Как поиск становится умнее





Отражённый интеллект: петля обратной связи

Организации проходят ступени по порядку. Сначала поиск по словам, затем ручные словари и таксономии, затем понимание запроса. Последняя ступень переносит ручную настройку в петлю обратной связи: система учится на своих выдачах.

Главное

Хорошо настроенный поиск по словам есть основа, на которой строится поиск на основе ИИ. Каждая следующая ступень опирается на первую и измеряется теми же метриками.

Языковые модели и поиск: генерация с опорой на найденное

Что умеет языковая модель. Понимает язык и в целом рассуждает о большинстве вопросов. Знания в ней сжаты с потерями: факты путаются, модель выдумывает правдоподобный ответ.

Что даёт ей поиск. Генерация, дополненная результатами поиска (RAG): поиск находит документы и передаёт их модели как контекст. Ответ получает опору в источнике.

Что модель даёт поиску. Толкует запрос, строит эмбеддинги для векторного поиска, резюмирует выдачу.

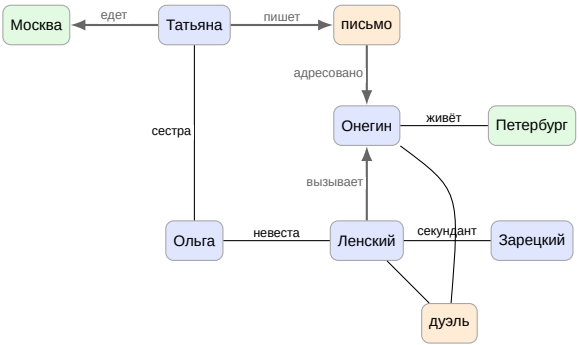
Управляемый ИИ. Человек видит, почему документ найден, и может поправить систему.



Главное

Генерация отвечает, поиск даёт ответу опору. Чем дальше вниз по лестнице, тем важнее, насколько хорошо найдены документы, и тем нужнее метрика поиска.

Текст содержит структуру: граф «Онегина»



Миф о неструктурированных данных. В тексте есть сущности и отношения между ними. Такой текст называют гиперструктурированным: граф в нём богаче таблиц базы данных.

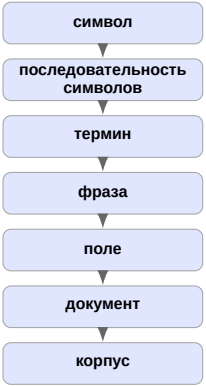
Нечёткие ключи. Одна сущность записана разными именами:

имя в тексте	вхождений
Татьяна (все формы)	99
Таня (все формы)	40
Онегин (все формы)	77
Евгений (все формы)	44
Ленский (все формы)	40
Владимир	11

Главное

Текст есть граф, записанный словами. Индекс видит в нём слова. Связи и разные имена одной сущности требуют следующих каналов: векторов и графа.

Уровни структуры текста



Каждый уровень даёт поиску своё:

- **символы и термины**: анализатор текста режет строку на токены, приводит к нижнему регистру, убирает стоп-слова, сводит формы к основе;
- **фразы**: два слова рядом значат больше, чем порознь;
- **поля**: первая строка строфы весит больше остального текста;
- **документ**: единица выдачи;
- **корпус**: статистика, по которой считается редкость слова.

Главное

Конвейер занятия проходит эти уровни снизу вверх: от символов к термину, от термина к полю и строфе, от строф к статистике корпуса.

Слово узнают по соседям

Распределительная гипотеза. Слова, которые встречаются в похожих контекстах, имеют похожие значения. «Слово узнают по компании, в которой оно встречается» (Дж. Р. Ферт, 1957).

Соседи по строфе в «Онегине». Во сколько раз чаще слово встречается в строфах вместе с данным именем, чем во всех строфах романа:

слово	самые частые соседи
Ленский	Зарецкий 6,6; Владимир 5,5; Ольга 4,6
Ольга	Владимир 9,7; глаза 5,8; ветреная 4,6
Татьяна	княгиня 3,8; бледная 3,6; луна 2,7
зима	осень 9,5; луг 7,1; снег 5,6

разреженный вектор, сегодня
одно измерение на термин: 4881 основа «Онегина», почти все координаты строфы равны нулю

↓

плотный эмбеддинг, лекция 6
сотни измерений, близкие по смыслу слова лежат рядом

два этапа поиска
сопоставление отбирает кандидатов, ранжирование упорядочивает их

Главное

Соседство по строфе уже находит, что Владимир и Ленский связаны. Сегодня соседство живёт в разреженных векторах и весах редкости, на лекции 6 оно станет плотным вектором.

Многозначность: слово «свет» в «Онегине»

Слово «свет» и его формы стоят в 46 строках романа. Значений у него по меньшей мере четыре:

значение	строка	строфа
общество	«Его не терпит высший свет»	гл. 8, XXXI
	«Ему наскучил света шум»	гл. 1, XXXVII
освещение	«Луны при свете серебристом»	гл. 7, XV
мир	«Другой!.. Нет, никому на свете»	письмо Татьяны
обращение	«Моложе был меня, мой свет»	гл. 3, XVIII

Стеммер сводит все формы к основе «свет». Индекс хранит одну метку, и все значения попадают в один список строф.

Полисемия. Английское слово «driver» значит: водитель, клюшка для гольфа, программа-драйвер, отвёртка, движущая сила.

Контекст. Термин есть «зависимый от контекста кластер значений с неоднозначной меткой». Без контекста термин истолковать нельзя.

Следствие. Неизменный список синонимов ошибается: «свет» как общество и «свет» как сияние луны требуют разных синонимов. Трансформер толкует каждый токен в окружении соседних.

Главное

Значение слова задаёт контекст. Запрос «свет луны» поднимет и строфы о высшем свете: поиск по словам видит метку и не видит значения.

Короткий запрос и намерение за ним

Запрос короче документа. В строфе «Онегина» в среднем 62 слова, в запросе выборки занятия 3,7 слова. Методы анализа текста обучены на предложениях и абзацах, в запросе им не на что опереться.

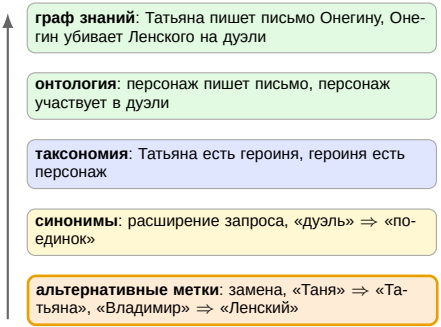
Что помогает. Внешний контекст: как фраза запроса чаще всего употребляется в корпусе, что искали похожие люди.

запрос из выборки	намерение	что нужно в ответе
«Я вас люблю, к чему лукавить»	найти точную строку	одна строфа
«письмо Татьяны»	найти известный текст	письмо целиком
«кто такой Зарецкий»	узнать факт	строфы, где он описан
«дуэль Онегина и Ленского»	собрать событие	пять строф шестой главы
«Москва»	неясно	город, поездка, бал?
«описание осени»	найти по смыслу	«Уж небо осенью дышало»

Главное

За запросом стоит намерение: строка, известный текст, факт, событие, тема. Поиск по словам лучше всего обслуживает первые два, остальные требуют понимания запроса. Метрики занятия покажут это числом.

Пять уровней знаний о предметной области



Каждый уровень расширяет предыдущий. Альтернативные метки заменяют слово равнозначным. Синонимы добавляют к запросу близкие слова. Таксономия раскладывает вещи по классам. Онтология задаёт отношения между типами. Граф знаний хранит сами факты.

Связь с модулем 1. Онтологию и граф мы строили в модуле 1. Сегодня поиск работает со строками. Нижние уровни связывают их: словарь синонимов и альтернативных меток берётся из онтологии и возвращается в поиск.

Главное

Знания о предметной области поднимают поиск со строк к вещам. Поэтому курс начался с онтологии: она станет словарём для поиска сегодня и графом для лекции 7.

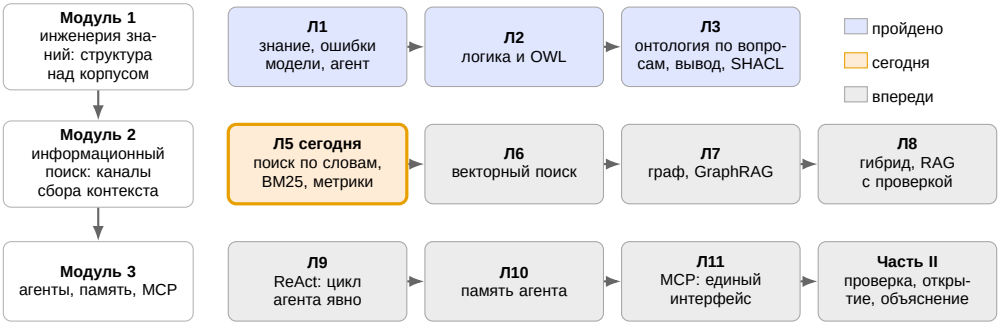
Понятия поиска на основе ИИ: сегодня и дальше в курсе

понятие	сегодня	дальше
сопоставление и ранжирование	инвертированный индекс и BM25	векторы и слияние выдач, лекции 6 и 8
уровни структуры текста	конвейер: токены, основы, поля строфы	
распределительная семантика	разреженный вектор, вес редкости	плотные эмбеддинги, лекция 6
многозначность и синонимия	видим в выдаче и измеряем	векторы и граф, лекции 6 и 7
знания о предметной области	словарь синонимов из онтологии	граф знаний, лекция 7
намерение запроса	выборка из 16 запросов разных типов	выбор канала агентом, лекция 9
генерация с опорой на поиск	инструмент агента с измеренной точностью	генерация с проверкой, лекция 8

Главное

Сегодня строим первую ступень поиска на основе ИИ: быструю, объяснимую и измеренную. Всё, что надстроится дальше, будет сравниваться с ней на той же выборке.

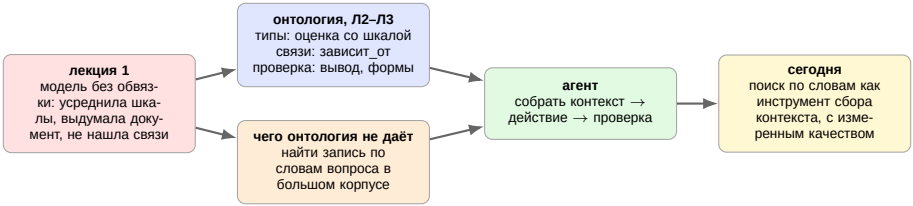
Дорожка курса: где мы сегодня



Главное

Сегодня первое занятие модуля 2. Вопрос: как найти по словам то, что нужно исследователю, и как измерить, насколько хорошо найдено.

Зачем начинали с онтологии



- Онтология ответила на вопросы «что следует из записанного» и «всё ли записано». Она не отвечает на вопрос «где в тысяче документов то, о чём спросили».
- Поиск есть первая часть агентного цикла: прежде чем проверять, нужно найти. Структура из модуля 1 вернётся в поиск полями, словарём синонимов и графом.

Главное

Модуль 1 дал проверку, модуль 2 даёт сбор контекста. Без первого ответ нельзя принять, без второго нечего проверять.

Что мы уже знаем об агенте

	компонент	что было в модуле 1
p_θ	модель	любая, сменная, не менялась
D	ведущее приложение	цикл `run_agent`, двадцать строк
T	инструменты	поиск, граф, правила, машина вывода, формы
P	контекст	корпус, словарь классов, вопросы в `AGENTS.md`
G	цель	критерий приёмки до действия: правило, аксиома, форма
V	верификатор	снаружи модели

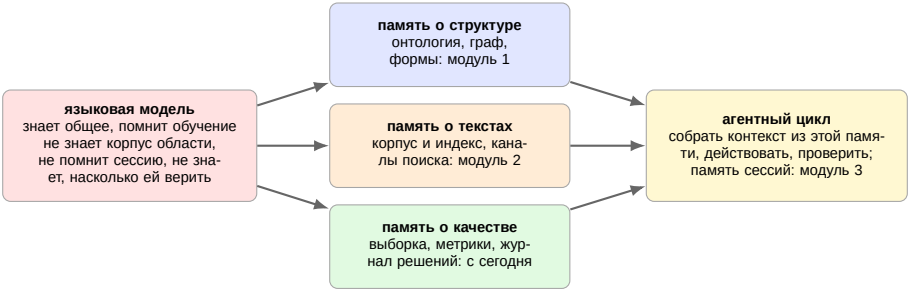


У каждого утверждения ответа указано происхождение: источник, проверено, выведено, противоречие в данных, не прошло проверку, найдено по словам, не подтверждено. Каждое утверждение сверяется с протоколом.

Главное

Модель не менялась четыре занятия. Менялись инструменты сбора контекста и верификаторы, и ответ редактора уточнялся с каждым занятием.

Память языковой модели

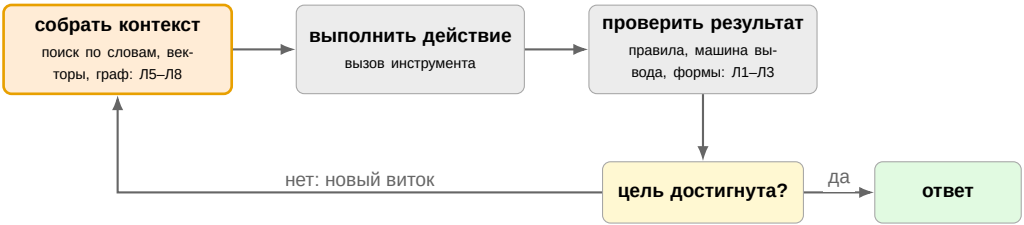


Поиску нужны два источника: тексты корпуса и сведения о том, что в них действительно отвечает на вопросы. У модели нет ни того, ни другого, пока их не дали инструментами.

Главное

Каждый модуль курса даёт модели один вид внешней памяти. Поиск по словам есть первый инструмент памяти о текстах, и его качество измеряется, потому что модель должна знать, насколько ему верить.

Агентный цикл и место поиска в нём



Модель выбирает следующее действие, ведущее приложение его исполняет. Результат проверяется вне модели по критерию приёмки, записанному до действия.

Главное

Всё, что строилось в модуле 1, стоит в клетке «проверить результат». Всё, что будет строиться в модуле 2, встаёт в клетку «собрать контекст».

Статья недели и что понадобится из модуля 1

Статья недели. Manning, Raghavan, Schütze. Introduction to Information Retrieval, 2008. Главы 1, 6.2–6.4, 8.1–8.4: инвертированный индекс, веса TF-IDF и векторная модель, оценка качества. Вопрос к ней: какая метрика из главы 8 подходит для пяти вопросов исследователя из задания лекции 1 и почему.

Что понадобится из модуля 1.

- корпус области `kg/corpus.csv` из задания лекции 1: 30 и больше утверждений с названием и формулировкой;
- пять вопросов исследователя с ожидаемыми ответами: сегодня они становятся первыми запросами тестовой выборки;
- онтология из заданий 2–3: её термины пригодятся как словарь синонимов в разделе «Границы».

Главное

Сегодня поиск по словам собирается полностью: инвертированный индекс, ранжирование по BM25 и измерение качества на размеченной выборке.

Корпус занятия: «Евгений Онегин»



Пушкин и Онегин на набережной Невы. Рисунок А. С. Пушкина, 1824.

Общественное достояние

Документ есть строфа романа: восемь глав, 358 строф и два письма, всего 360 документов и 24 тысячи слов. Текст из собрания RusLit, общественное достояние.

Два поля: первая строка строфы и весь текст.

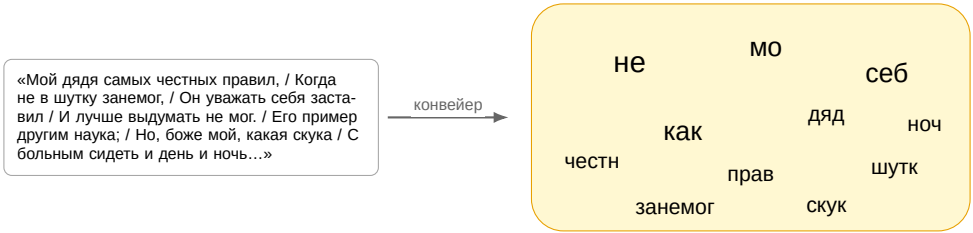
Обозначение «глава.строфа»: 6.IX есть глава 6, строфа IX. Письма обозначены 3.ПТ (Татьяна) и 8.ПО (Онегин).

Запросы пяти видов: цитата, слова строфы, одно слово, имя и событие, смысл своими словами. Шестнадцать запросов размечены по строфам.

Главное

Роман знают все, и каждую выдачу можно проверить по памяти. На нём механизм поиска виден сам по себе, без предметного спора.

Документ как мешок слов



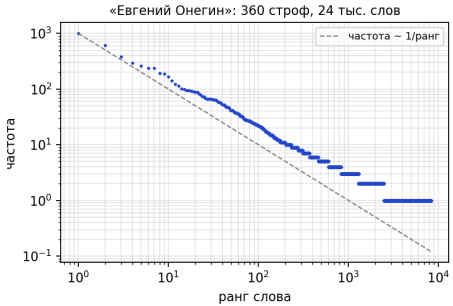
48 токенов, размер слова по частоте

- Порядок слов забыт, остались слова и частоты. Ирония строфы потеряна, для поиска осталось всё нужное.
- Самое частое слово строфы, «не», ничего о ней не говорит: оно стоит в 216 строфах из 360. Отсюда следующий шаг: решить, какие слова оставлять и в какой форме.

Главное

Запрос тоже мешок. Поиск по словам сравнивает мешки: какие слова общие и сколько они весят.

Закон Ципфа на «Онегине»



В тексте строф 22 567 слов, с первыми строками около 24 тысяч. Разных словоформ 8357, и 70 % из них встречаются один раз. Половину всех слов дают 462 самые частые словоформы, 5,5 % словаря.



Дж. К. Ципф

(1902–1950),

снимок 1917 года

Закон Ципфа. Расставим слова по частоте: самое частое получает ранг 1, следующее ранг 2 и так далее. Частота слова примерно обратно пропорциональна его рангу: $f(r) \approx C/r$. Второе слово встречается примерно вдвое реже первого, десятое примерно в десять раз реже.

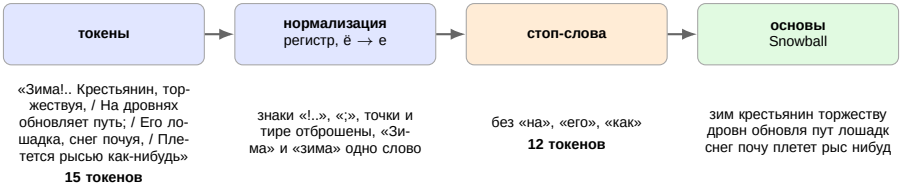
ранг r	слово	частота	по формуле $1004/r$
1	и	1004	1004
2	в	605	502
3	не	386	335
10	что	166	100
100	сердца	22	10

Закон приблизительный: редкие слова встречаются чаще формулы. На графике точки идут вдоль пунктирной прямой «частота $\sim$ 1/ранг».

Главное

Немногие слова есть почти в каждой строфе и не помогают выбрать нужную. Нужную строфу выдают редкие слова. Поэтому частые слова убирают как стоп-слова, редким словам дают больший вес IDF.

Конвейер на строфе «Зима!..»



Те же четыре шага применяются к строфе при индексации и к запросу при поиске. Запрос «зимой на дровнях» превратится в «зим дровн» и совпадёт со строфой, хотя ни одна словоформа не повторена буквально.

Главное

Конвейер решает, что считать одним словом. На корпусе занятия он влияет на качество поиска сильнее, чем выбор формулы ранжирования.

Токенизация стихов

Токен есть последовательность букв или цифр. Всё остальное разделяет токены: пробелы, знаки, тире, многоточия, кавычки.

Решения, которые приходится принимать в «Онегине».

- Дефис: «по-французски», «как-нибудь» одно слово или два? Токенизатор лекции делит на два.
- Сноски издания вида [1], [2] убраны при разборе на строфы, иначе цифры попали бы в словарь.
- Буква ё: «её», «ещё» приводятся к «ее», «еще», иначе одно слово разойдётся на две записи.
- Римские номера строф: в текст не входят, это обозначение документа.

«Ах, ножки, ножки! где вы ныне?»

ах ножки ножки где вы ныне

Восклицание, запятые и вопросительный знак исчезли. Повтор «ножки, ножки» сохранился: частота слова в строфе равна двум, и это пригодится весу.

Главное

Каждое решение токенизатора меняет словарь. Токенизатор для запроса и для строф один и тот же, иначе выдача будет пустой.

Стоп-слова: «и», «в», «не» в «Онегине»

слово	сколько раз в романе
и	1056
в	652
не	413
он	330
на	273
я	257
с	252
но	222

Восемь самых частых слов романа ничего не говорят о строфе. Они есть почти в каждой.

Стоп-слова убирают то, что есть почти везде. Список лекции содержит 50 слов, список nltk для русского 151.

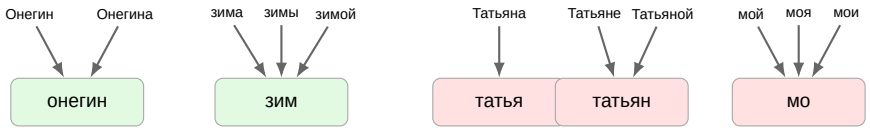
Ловушка. В список nltk входит «не». Цитата «Вы ко мне писали, не отпирайтесь» без «не» теряет смысл: запрос «не отпирайтесь» превращается в «отпирайтесь».

В «Онегине» «не» стоит в 224 строфах из 360 и само по себе ничего не различает. Убирать его или нет, решается по корпусу и записывается в журнал.

Главное

Готовый список стоп-слов читается глазами до использования. Список хранится рядом с индексом как его часть.

Стемминг на «Онегине»: что склеилось и что нет



Стемминг отсекает окончания по правилам языка. Словарь романа сжимается с 8300 словоформ до 4881 основы. Ошибки предсказуемы: «Татьяна» даёт «татья», «Татьяной» даёт «татьян», и запрос «Татьяна» не находит строфу «Итак, она звалась Татьяной». То же с «любовь» и «любви»: «любов» и «любв».

Главное

Склейка словоформ даёт самый большой выигрыш из шагов конвейера. В части о метриках это будет видно числом: без стоп-слов и основ качество поиска на «Онегине» падает почти на треть.

Лемматизация: Татьяна, Татьяне, Татьяной

Лемматизация приводит слово к словарной форме по морфологическому словарю: «Татьяне», «Татьяной» → «Татьяна», «любви» → «любовь», «писали» → «писать».

Для русского языка: pymorphy3, библиотеки на основе Natasha. Они знают части речи и падежи, поэтому склеивают то, что стеммер развёл.

Цена: словарь, скорость в десятки раз ниже, неоднозначности формы («стали» есть глагол и металл).

форма	стеммер	лемма
Татьяна	татья	Татьяна
Татьяной	татьян	Татьяна
любовь	любов	любовь
любви	любв	любовь
писали	писа	писать
письмо	письм	письмо

Имена героев и чувства в стихах стоят во всех падежах, и для романа лемматизация заметно точнее.

Главное

Стемминг и лемматизация решают одну задачу, склеить словоформы. Выбор между ними есть компромисс точности и цены, и его проверяют метрикой на выборке.

Ловушка конвейера на запросе по ходу показа

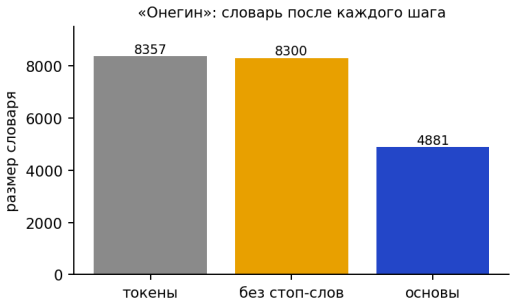


Исправление: отбрасывать и основы стоп-слов, флаг `stop_stems=True`. Выдача состоит из строф с Зарецким. Порядок шагов конвейера есть решение, и оно записывается в журнал.

Главное

Ошибка конвейера видна только на выдаче: слово, которого нет в запросе, принесло строфу, которой нет в ответе.

Словарь «Онегина» до и после конвейера



8357 словоформ. Без стоп-слов 8300: их немного, и они самые частые. Основ 4881, почти вдвое меньше словоформ.

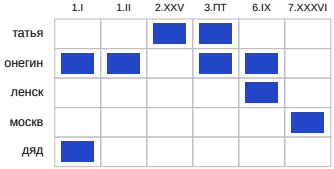
Средняя длина строфы 67 токенов, после удаления стоп-слов 54.

В журнал записываются: токенизатор и обработка дефиса, список стоп-слов и исключения, стеммер или лемматизатор, поля и их веса, параметры k_1 и b.

Главное

Индекс, собранный другим конвейером, даёт другие метрики. Без записи решений таблицу метрик нельзя воспроизвести.

От матрицы к инвертированному индексу



матрица «слово × строфа»: 4881 × 360, заполнена на доли процента

по строкам

татья df 61: 2.XXV, 3.ПТ, 3.X, …

онегин df 67: 1.I, 1.II, 3.ПТ, 6.IX, …

ленск df 39: 2.XII, 6.IX, … до главы 6

москв df 8: 7.XXXVI, 7.XXXVII, …

дяд df 4: 1.I, 1.LII, 6.XXVII, 6.IV

зебр df 0

инвертированный индекс: слово → список строф с частотами

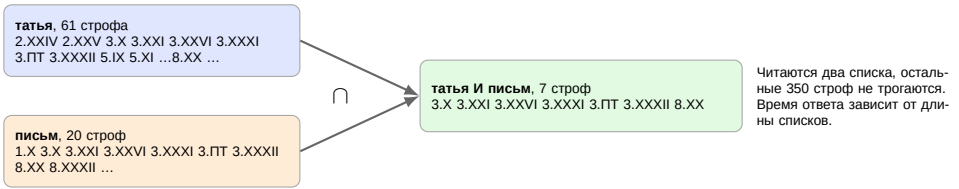
df, документная частота: в скольких документах слово встречается хотя бы один раз. Основа «татья» стоит в 61 строфе из 360, и df равно 61, сколько бы раз Татьяна ни упоминалась внутри одной строфы. Частота внутри документа есть другое число, TF.

Номер строфы записан как «глава.строфа»: 6.IX есть глава 6, строфа IX. 3.ПТ есть письмо Татьяны из главы 3.

Главное

Индекс есть оглавление романа по словам. Число df уже рассказывает сюжет: Онегин в каждой пятой строфе, Ленский исчезает после шестой главы, дядя упомянут четырежды.

Булев поиск по «Онегину»

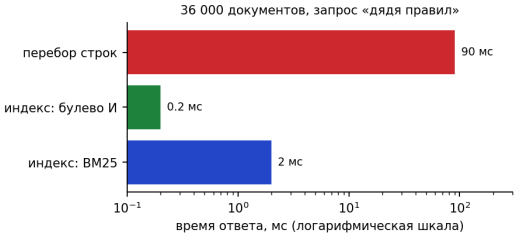


В пересечение попали письмо Татьяны, строфы о том, как она его пишет и отправляет, и строфа 8.XX, где письмо вспоминается. Порядка внутри ответа нет: булев поиск отвечает «да» или «нет». Для порядка нужны веса.

Главное

Индекс делает поиск быстрым: обрабатываются только строфы, где слово встретилось. Порядок выдачи есть следующая задача.

Гонка: перебор против индекса



Корпус размножен в сто раз, 36 000 документов. Перебор строк 90 мс, булев запрос по индексу 0,2 мс, BM25 по спискам вхождений 2 мс. Индекс строится 1,7 с один раз.

Перебор растёт с корпусом линейно, индекс растёт с длиной списков. На запросе со словом «Татьяна» BM25 занимает 80 мс: основа стоит в 61 строфе, и список длинный.

Главное

Редкие слова ценны дважды: они точнее и быстрее.

Три веса на запросе «письмо Татьяны»

TF, частота в строфе: сколько раз слово встретилось.

IDF, редкость в корпусе: $\log \frac{N}{\mathrm{df}}$, где N = 360 строф, df число строф со словом.

TF-IDF: произведение. Часто здесь и редко вообще.

	письм	татья
df	20	61
IDF	2,89	1,78
TF в 3.XXXI, 48 слов	2	2
TF в письме Татьяны, 309 слов	1	1

Слово «письмо» реже имени героини и весит больше. Имя Татьяны стоит в каждой шестой строфе и различает строфы хуже.

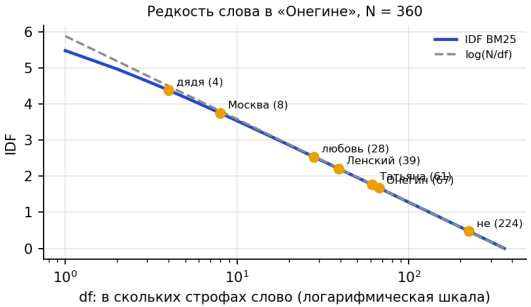
Строфа 3.XXXI «Письмо Татьяны предо мною» дважды называет и письмо, и Татьяну. Само письмо Татьяны называет их по разу: в тексте письма слова «письмо» почти нет, есть «Я к вам пишу».

Идея IDF: Карен Спэрк Джонс, 1972.

Главное

IDF есть вклад корпуса в оценку: слово ценно настолько, насколько оно редко в этом корпусе.

Вес редкости в «Онегине»



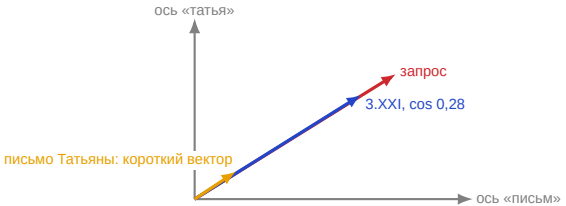
Имя героя стоит в каждой пятой строфе и весит 1,68. Слово «дядя» стоит в четырёх строфах и весит 4,38. Слово «не» стоит в 224 строфах и почти ничего не весит, хотя из списка стоп-слов оно исключено.

В запросе «дуэль Онегина и Ленского» выдачу определяет слово «дуэль», вклад имени героя самый малый.

Главное

Онегин есть стоп-слово своего романа. Редкость считается внутри корпуса, и IDF это знает.

Косинус на запросе «письмо Татьяны»



Строфа и запрос суть векторы весов TF-IDF. Близость есть косинус угла между ними: сумма произведений весов по общим словам, делённая на длины векторов.

Выдача: 3.XXI 0,28, 3.XXXI 0,23, 8.XXXII 0,17, 8.XX 0,16, 3.XXXII 0,13. Само письмо Татьяны в первую пятёрку не попало: в его 309 словах вес двух слов запроса растворился, длинный вектор почти перпендикулярен запросу.

Три слабости. Частота считается линейно: десятая встреча слова весит как первая. Длина учитывается грубо: длинное письмо проигрывает из-за знаменателя, короткая строфа с одним словом выигрывает. Частое слово получает вес около нуля без защиты.

Главное

TF-IDF задаёт идею «часто здесь, редко вообще». BM25 исправит три её слабости.

Вектор и его представление: плотное и разреженное

Вектор строфы имеет одно измерение на каждую основу словаря «Онегина»: 4881 измерение.

что	сколько
измерений в векторе	4881
ненулевых у запроса «письмо Татьяны»	2
ненулевых у строфы в среднем	45
доля нулей в векторе строфы	99 %

Такой вектор называют **разреженным**: почти все координаты равны нулю. Вектор, где почти все координаты ненулевые, называют **плотным**.

Представление есть способ хранить вектор.

- Плотное представление хранит все координаты подряд, нули тоже.
- Разреженное хранит только ненулевые: пары «основа, вес». Инвертированный индекс и есть разреженное представление всех строф сразу.

На оценку влияют только общие слова запроса и строфы. Остальные координаты в скалярное произведение дают нули. Поэтому для ранжирования достаточно координат слов запроса, и индекс отдаёт именно их.

Главное

Разреженность есть свойство вектора, представление есть способ его хранить. Поиск по словам считает разреженные векторы через разреженное представление, и поэтому быстр.

Разреженный вектор не знает близких слов

Сцена дуэли занимает строфы 6.XXIX–6.XXXII. Что даёт индекс на слова, близкие по смыслу:

запрос	строф	какие
«дуэль»	2	6.IX вызов, 6.XXVI
«поединок»	0	слова нет в индексе
«выстрел»	1	6.XXX
«пистолет»	8	среди них 6.XXIX и 6.XXX

Запрос «поединок» в разреженном представлении есть нулевой вектор. С любой строфой у него косинус ноль, выдача пуста.

У каждого слова своё измерение, и измерения не связаны между собой. «Дуэль», «поединок», «выстрел» и «пистолет» для индекса суть четыре независимые оси.

Сама сцена дуэли слова «дуэль» не содержит. Пушкин пишет «пистолеты уж блеснули», «Онегин выстрелил». Найти сцену по слову «дуэль» индекс не может.

Ответ на это есть представление, в котором близкие по смыслу слова получают близкие векторы.

Главное

Поиск по словам находит только совпадение. Близость смысла в разреженном векторе не записана: одно слово, одна ось.

Плотный эмбеддинг: признаки вместо слов

сцена	любовь	опасность	праздник	природа	слово	город
письмо Татьяны	5	1	0	0	5	0
ответ в саду	4	1	0	2	4	0
письмо Онегина	5	1	0	0	5	3
последнее объяснение	5	1	0	0	4	3
бал на именинах	2	2	5	0	1	0
бал в Петербурге	3	0	5	0	1	5
вызов на дуэль	0	4	0	0	4	0
дуэль	0	5	0	1	1	0
сон Татьяны	3	4	0	4	0	0
зима в деревне	0	0	1	5	0	0
приезд в Москву	1	0	2	1	0	5

Учебные векторы: значения от 0 до 5 поставлены вручную.

Эмбеддинг есть вектор, в который «встроено» понятие: точка в пространстве смысла.

Здесь измерений шесть, и у каждого понятное имя. У разреженного вектора их было 4881, по одному на слово.

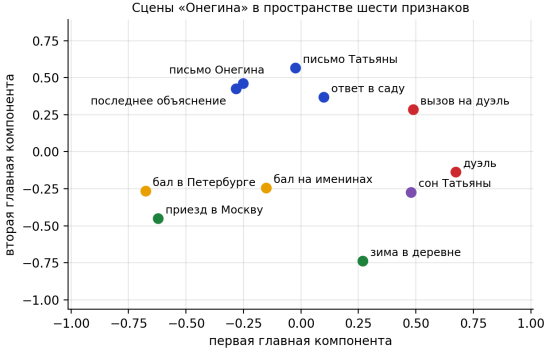
Сцена дуэли получает высокое значение «опасности» независимо от того, какими словами она написана. Запрос «поединок» в таком пространстве тоже попал бы в «опасность».

Эмбеддинги модели имеют сотни измерений, и имён у них нет: признаки модель находит сама.

Главное

Плотный эмбеддинг заменяет «какие слова есть» на «какими свойствами обладает». Близость смысла становится близостью точек.

Сходство эмбеддингов: косинус



Шесть измерений спроецированы на плоскость двух главных компонент.

Ближайшие к «дуэли»
вызов на дуэль 0,82 · сон Татьяны 0,72 · бал на именинах 0,36 · … · бал в Петербурге 0,02

Ближайшие к «письму Татьяны»
ответ в саду 0,94 · письмо Онегина 0,92 · последнее объяснение 0,90 · … · зима в деревне 0,00

Ближайшие к «зиме в деревне»
сон Татьяны 0,61 · ответ в саду 0,32 · приезд в Москву 0,25 · … · письма 0,00

Косинус тот же, что для разреженных векторов: $\cos = \dfrac{a \cdot b}{|a|\,|b|}$. Меняется пространство.

Главное

Сцены одного рода собираются рядом: письма и объяснения, балы, опасность. Сон Татьяны лежит между опасностью и природой, как и в романе: страшный зимний лес.

Эмбеддинг, обученный на строфах «Онегина»

основа	ближайшие соседи и косинус
письм	слаб 0,69 · **послан 0,63** · заран 0,62 · княгин 0,61
ленск	**ольг 0,67** · **владимир 0,58** · онегин 0,57 · сво 0,53
зим	кровл 0,84 · **зимн 0,78** · забор 0,77 · ковр 0,76
снег	ярк 0,78 · **медвед 0,70** · ковр 0,68 · серебр 0,66
смерт	юнош 0,70 · лежа 0,62 · зелен 0,60 · гробов 0,58
татья	бледн 0,59 · он 0,58 · е 0,56 · все 0,54

Признаки здесь никто не задавал. Матрица «основа × строфа» с весами TF-IDF сжата сингулярным разложением до 50 измерений: латентно-семантический анализ. Каждая основа получила плотный вектор.

Распределительная гипотеза в действии: слова, которые встречаются в одних строфах, получают близкие векторы.

- «письмо» рядом с «посланием»;
- «Ленский» рядом с Ольгой и своим именем Владимир;
- «снег» рядом с медведем из сна Татьяны.

Шум. Рядом с «Татьяной» стоят «он», «е», «все»: 360 строф мало. Языковые модели учатся на миллиардах слов, их эмбеддинги разбирает лекция 6.

Главное

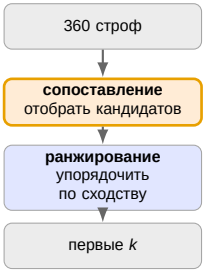
Эмбеддинг можно получить из самого корпуса. Даже 360 строф дают часть верных соседей, и синоним «послание» находится без словаря.

Что кодирует эмбеддинг и как с ним искать

Единица эмбеддинга: слово, фраза, предложение, абзац, документ. Для поиска по строфам нужен вектор строфы и вектор запроса в одном пространстве.

Измерения абстрактны. Модель находит признаки сама, и подписать их словами обычно нельзя. Для поиска это не мешает, пока растёт качество выдачи.

Любая модальность. Векторы строят для изображений, звука, видео и поведения. Тогда текстовый запрос находит картинку.



У плотного вектора нет слов, по которым можно отфильтровать строфы. Кандидатов отбирает индекс ближайших соседей, он появится в лекции 6.

Главное

Поиск по эмбеддингам проходит те же два этапа: сопоставление и ранжирование. Меняется то, что сравнивается: точки смысла вместо совпавших слов.

Сигналы пользователей: та же гипотеза на поведении

Контент и сигналы суть два источника, на которых учится поиск на основе ИИ.

- **Контент**: слова встречаются вместе в документах, из этого выводится смысл.
- **Сигналы**: запросы, клики, покупки. Похожие люди ищут похожее. Из журналов запросов выводятся связанные термины, синонимы, опечатки.

Одним приложениям хватает контента, другим сигналов. Лучше всего иметь и то и другое.

Персонализация есть самое хрупкое измерение намерения. Человек искал iPhone. Поднимать ли Apple, когда он ищет наушники? Может быть, он сравнивал iPhone с другими телефонами.

Языковые модели приносят общее понимание языка готовым. Дообучение на данных области подстраивает их под её термины.

В курсе журналов поведения нет. Поиск учится на контенте: на словах, векторах и графе.

Главное

Распределительная гипотеза работает и на словах, и на людях. Курс берёт контентную половину: из неё строятся все каналы модуля 2.

Что эмбеддинги решают из трудностей языка

трудность	пример на «Онегине»	эмбеддинг
синонимия	«поединок» и «дуэль», «послание» и «письмо»	близкие векторы: помогает
перефразировка	«имя героини романа»	вектор фразы может оказаться ближе к строфе «Итак, она звалась Татьяной»: проверка в лекции 6
многозначность	«свет» как общество и как сияние луны	один вектор на слово смешивает значения: нужен вектор слова в контексте, его дают трансформеры
точная строка	«Я вас люблю, к чему лукавить»	совпадение слов размывается: поиск по словам обычно надёжнее
связи	ответ Онегина на письмо Татьяны	связи в векторе нет: нужен граф

Поэтому каналы не заменяют друг друга. Слова дают точность на точных запросах, векторы дают близость смысла, граф даёт связи.

Главное

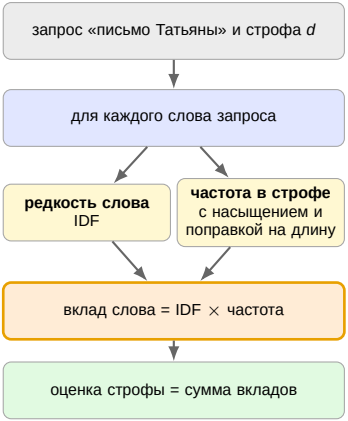
Эмбеддинги закрывают синонимию и перефразировку, две главные границы поиска по словам. Многозначность и связи остаются следующим каналам.

Что такое BM25

BM25 есть функция ранжирования: по запросу и документу она вычисляет одно число, оценку релевантности. Документы сортируются по убыванию оценки, и получается выдача.

Название. BM значит Best Matching, «наилучшее соответствие». Число 25 есть номер варианта весовой схемы в экспериментальной системе Okapi Лондонского городского университета. Формулу опубликовали Стивен Робертсон и соавторы в 1994 году.

Модель документа та же, что у TF-IDF: мешок слов. Порядок слов и смысл не учитываются, учитываются частоты.



Главное

BM25 отвечает на вопрос «насколько эта строфа подходит к запросу» одним числом. Число складывается из вкладов слов запроса, и каждый вклад можно показать отдельно.

BM25 вырос из TF-IDF

часть	TF-IDF	BM25
частота слова	f: растёт без предела	$\frac{f(k_1+1)}{f+k_1 \cdot \text{норма}}$: насыщается
длина документа	через нормировку вектора в косинусе	явная поправка $b \cdot \frac{dl}{avgdl}$
редкость слова	$\log \frac{N}{\text{df}}$	$\log\left(\frac{N-\text{df}+0{,}5}{\text{df}+0{,}5}+1\right)$
сборка	косинус векторов	сумма вкладов слов запроса

Основа та же: вес слова есть произведение частоты в документе на редкость в корпусе. BM25 добавляет к TF-IDF две поправки, на насыщение и на длину, и получает их из вероятностной модели релевантности.

Вклад слова «письмо» в оценку строфы. В корпусе «письм» стоит в 20 строфах из 360. Здесь f есть число вхождений в строфе, dl её длина, $avgdl$ средняя длина строфы.

f	TF-IDF	BM25 при $dl = avgdl$	BM25 при $dl = 2\,avgdl$
1	2,89	2,87	1,98
2	5,78	4,10	3,10
3	8,67	4,78	3,82
5	14,45	5,52	4,70
10	28,90	6,24	5,68

$k_1 = 1{,}5$, $b = 0{,}75$. Предел вклада BM25 равен $(k_1+1) \cdot \text{IDF} = 7{,}17$.

При одном вхождении веса почти равны. Дальше TF-IDF растёт линейно, BM25 быстро упирается в предел. В длинной строфе то же вхождение весит меньше.

Главное

BM25 есть TF-IDF с двумя поправками. Десятое повторение слова почти ничего не добавляет, и длинный документ не выигрывает только за счёт длины.

Когда используют BM25

Где он работает

- **Полнотекстовый поиск по умолчанию**: Lucene, Elasticsearch, OpenSearch, Solr, полнотекстовые индексы баз данных.
- **Первый этап поиска**: BM25 быстро отбирает сотню кандидатов из миллионов, затем их переупорядочивает нейронная модель.
- **Гибридный поиск**: выдача BM25 сливается с выдачей векторного поиска, лекция 8.
- **Поиск для генерации**: поисковая часть RAG и инструмент поиска у агента.
- **Базовая линия** в исследованиях: в наборе тестов BEIR (2021) BM25 остаётся сильным соперником нейронных моделей без дообучения.

Когда его выбирают

- в запросах точные термины, имена, номера, цитаты;
- нет размеченных данных для обучения модели;
- нужна скорость и малый расход памяти;
- нужно объяснить каждую строку выдачи по вкладам слов.

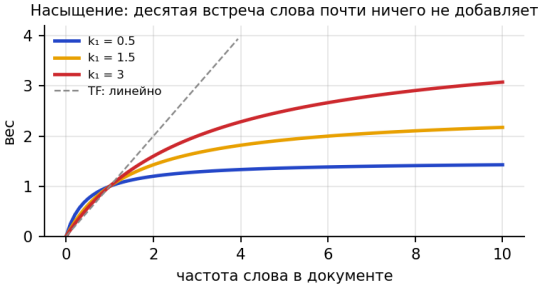
Когда его мало

- синонимы и перефразировки: «поединок» вместо «дуэли»;
- вопрос словами, которых нет в ответе;
- связи между документами: ответ на письмо.

Главное

BM25 есть рабочая лошадь поиска: быстрая, без обучения и объяснимая. Векторы и граф добавляют к нему то, чего не видно в словах.

Поправка первая: насыщение частоты, k_1



В TF-IDF вес растёт линейно с частотой. BM25 пропускает частоту через дробь

$$\frac{f(k_1+1)}{f+k_1},$$

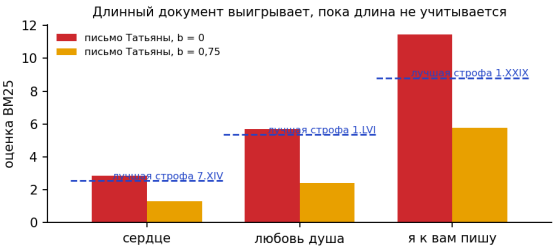
которая растёт всё медленнее и не превышает k_1+1.

$k_1 \to 0$: повторы не считаются. k_1 большое: почти линейно. Обычно 1,2–2,0, в лекции 1,5.

Главное

Первая встреча слова говорит о документе больше всего, десятая почти ничего.

Поправка вторая: длина документа, *b*. Письмо Татьяны



Строфа содержит около 50 слов, письмо Татьяны 309. В 309 словах слово «сердце» встретится почти наверняка.

Норма длины $1 - b + b \cdot dl/avgdl$ стоит в знаменателе. При $b = 0$ длина не учитывается, и письмо выигрывает любой запрос о чувствах. При $b = 0{,}75$ норма письма равна 5,2, и оно уступает коротким строфам.

«Я к вам пишу» есть цитата из письма, и при $b = 0{,}75$ письмо на третьем месте: длина наказала верный ответ. Параметр настраивается по выборке.

Главное

Нормализация длины видна там, где документы разной длины. Строфа около 50 слов, письмо в шесть раз длиннее, и письмо Татьяны показывает действие *b* одним запросом.

Формула BM25 целиком

$$\text{BM25}(q,d) = \sum_{w \in q} \underbrace{\log\left(\frac{N - \text{df}(w) + 0{,}5}{\text{df}(w) + 0{,}5} + 1\right)}_{\text{редкость слова}} \cdot \underbrace{\frac{f_d(w)\,(k_1+1)}{f_d(w) + k_1\left(1 - b + b \cdot \dfrac{dl}{avgdl}\right)}}_{\text{частота с насыщением и поправкой на длину}}$$

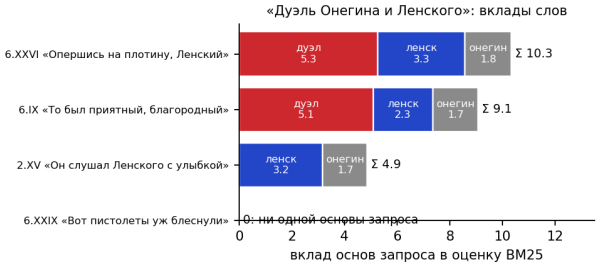
- сумма по словам запроса: слова независимы;
- IDF с поправками остаётся положительным;
- k_1 управляет насыщением, b учётом длины.

- не смотрит на порядок слов;
- не знает синонимов;
- не различает, из какого поля слово: это BM25F.

Главное

Формула эмпирическая, обоснована вероятностной моделью релевантности и остаётся основой полнотекстового поиска с 1994 года. Экзаменационный вопрос 8.

Вклад каждого слова: дуэль Онегина и Ленского



Оценка BM25 есть сумма вкладов слов запроса. Первые две строфы набрали больше всех благодаря слову «дуэль»: 5,3 и 5,1. Имя героя добавляет меньше двух.

Сама сцена дуэли, 6.XXIX «Вот пистолеты уж блеснули», получает ноль: в ней нет ни слова «дуэль», ни фамилий.

Главное

У каждой строки выдачи есть объяснение по вкладам слов. Выдачу можно разобрать до основ, и это сильная сторона поиска по словам.

Точная строка находится всегда

Запрос «мой дядя самых честных правил». Основы: мо, дяд, сам, честн, правил.

BM25F	строфа	первая строка
21,59	1.I	Мой дядя самых честных правил
10,94	1.LII	Вдруг получил он в самом деле
8,36	6.XXVII	«Мой секундант?» — сказал Евгений

Отрыв вдвое: четыре редкие основы совпали в одной строфе, и каждая дала вклад с большим IDF. Строфа 1.LII попала по словам «дядя» и «сам»: там дядя умирает.

То же для «Я вас люблю, к чему лукавить» (8.XLVII, 18,1), «Москва, как много в этом звуке» (7.XXXVI, 17,1), «Любви все возрасты покорны» (8.XXIX).

Это область, где поиск по словам незаменим: цитата, номер, имя. NDCG равен единице на всех пяти запросах с точной строкой.

Запрос «брусничная вода» находит 3.III и 3.IV, обе строфы у Лариных, где её подают и где от неё опасаются вреда.

Главное

Чем реже слова запроса, тем увереннее выдача. Цитата из четырёх редких слов даёт отрыв вдвое от второго места.

Мини-пример вручную: три отрывка о зиме

	отрывок	*dl*
d1	Зима!.. Крестьянин, торжествуя, на дровнях обновляет путь.	6
d2	В тот год осенняя погода стояла долго на дворе, зимы ждала, ждала природа. Снег выпал только в январе.	14
d3	И вот уже трещат морозы и серебрятся средь полей.	7

Запрос «зима снег», основы: зим, снег. $N = 3$, $avgdl = 9$, $k_1 = 1{,}5$, $b = 0{,}75$.

IDF: зим в двух отрывках, 0,470; снег в одном, 0,981.

Нормы длины: d1 0,75, d2 1,42, d3 0,83.

d1. зим: $0{,}470 \cdot \frac{2{,}5}{1+1{,}5 \cdot 0{,}75} = 0{,}553$. Сумма 0,553.

d2. зим 0,376, снег 0,785. Сумма 1,161.

d3. ни одной основы запроса: 0.

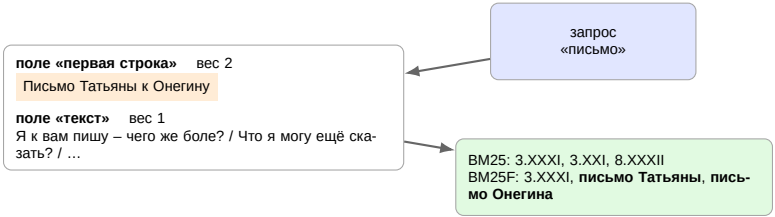
Выдача: d2, d1, d3. Функция из модуля даёт те же числа.

d2 длиннее, но в нём есть оба слова. d3 о зиме, о морозах и инее, и получает ноль: слов запроса в нём нет.

Главное

Расчёт BM25 вручную занимает три строки на документ. Третий отрывок заранее показывает главную границу поиска по словам.

Поля строфы: первая строка и текст



BM25F складывает частоты по полям с весами и нормирует длину каждого поля отдельно. Без полей письма проигрывают коротким строфам: слово «письмо» в них одно на сотни слов. С полем заголовка оба письма поднимаются на второе и третье место, потому что слово стоит в их названии.

Главное

Поля суть структура, известная до поиска. Первая точка, где структура помогает словам: без онтологии и без графа, одними полями.

BM25 в библиотеках

В библиотеках.

- `rank_bm25`: BM25 в тридцать строк Python, параметры по умолчанию $k_1 = 1{,}5$, $b = 0{,}75$;
- Lucene, Elasticsearch, OpenSearch: BM25 как оценка по умолчанию с 2016 года (Lucene 6.0, Elasticsearch 5.0), $k_1 = 1{,}2$, $b = 0{,}75$, поля с весами;
- PostgreSQL, SQLite FTS5: полнотекстовый индекс внутри базы данных.



Карен Спэрк Джонс, фото M. Kuhn, CC BY 2.5

Откуда взялось. IDF ввела Карен Спэрк Джонс в 1972 году. Вероятностная модель релевантности Робертсона и Спэрк Джонс, 1976. BM25 как её рабочая формула появился в системе Okapi в 1994 году [Robertson, Zaragoza 2009].

В курсе. Индекс пишется самостоятельно по образцу `search_bm25.py`, чтобы параметры и конвейер были видны. В проекте используется библиотека, и её параметры записываются в журнал.

Главное

BM25 есть стандарт отрасли больше тридцати лет. Своя реализация нужна для понимания того, что именно настраивается.

Каждая часть запроса есть функция оценки

BM25 есть одна функция оценки. В оценку можно добавить и другие:

бонус	что поднимает	на «Онегине»
за поле	совпадение в важном поле	первая строка строфы с весом 2: это BM25F
за фразу	слова запроса стоят подряд	«письмо Татьяны» подряд в тексте
за категорию	документы нужной категории	строфы нужной главы
за свежесть	новые документы	в романе неприменимо, важно для новостей
за популярность	документы, которые чаще выбирают	хрестоматийные строфы, если есть журнал выбора
за близость места	документы рядом с пользователем	неприменимо
семантическое расширение	документы со связанными словами	синонимы из онтологии: «Таня» к «Татьяне»

Каждый бонус есть признак документа относительно запроса. Оценка документа складывается из признаков с весами.

Главное

Запрос есть вектор признаков, оценка есть функция от них. Текстовое сходство остаётся одним признаком из многих.

Сложение и умножение признаков

Сложение. Каждый признак приводят к шкале от 0 до 25 и складывают. Четыре признака дают максимум 100. Вклад каждого виден и ограничен.

Умножение. Оценку умножают на множитель признака. Бонусы наслаиваются, шкалы заранее согласовывать не нужно. Большой множитель может заглушить остальные признаки.

Опыт. Запрос «письмо Татьяны», признак «слова запроса стоят подряд»: такие строфы 3.ПТ, 3.XXXI и 3.XXVI.

ранг	BM25F	сложение $25 \cdot \frac{s}{s_{\max}} + 25 \cdot$ фраза	умножение $s \cdot (1 +$ фраза$)$
1	**3.XXXI**	**3.XXXI**	**3.XXXI**
2	**3.ПТ**	**3.ПТ**	**3.ПТ**
3	**3.XXI**	3.XXVI	3.XXVI
4	8.XX	**3.XXI**	**3.XXI**
5	3.XXXII	8.XX	8.XX

Жирным выделены строфы, нужные по разметке выборки.

Бонус поднял строфу 3.XXVI «Письмо Татьяны перевесть»: слова подряд, по разметке она не нужна. Нужная 3.XXI опустилась на ступень.

Главное

Сложение даёт предсказуемый вклад, умножение даёт гибкость. Оба меняют порядок, и проверить изменение можно только метрикой.

Бонус проверяют на выборке

ранжирование	NDCG@10	MAP
BM25F	0,689	0,643
+ фраза, сложение, вес 5	0,689	0,643
+ фраза, сложение, вес 25	0,688	0,637
$\times$ (1 + фраза)	0,688	0,637

16 запросов к «Онегину». Метрики NDCG@10 и MAP вводятся в разделе «Метрики»: чем ближе к единице, тем лучше порядок.

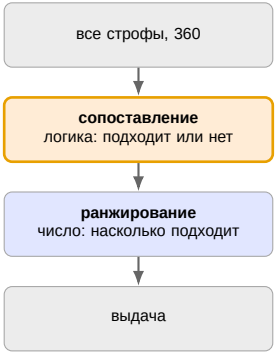
Бонус за фразу на выборке «Онегина» ничего не дал. Запросы-строки и так находят свою строфу первой. На запросах о событиях слова запроса подряд в тексте не стоят.

Хороший бонус для одного запроса может оказаться вредным для другого. Ручной подбор весов быстро упирается в число признаков. Следующий шаг есть обучение ранжированию: веса признаков подбирает модель по размеченной выборке.

Главное

Признак входит в ранжирование, только если метрика на выборке выросла. Интуиция «фраза важнее слов» на «Онегине» не подтвердилась.

Сопоставление и ранжирование: две разные задачи



Сопоставление отбирает множество документов: это фильтр, ответ «да» или «нет».

Ранжирование упорядочивает отобранное по оценке.

Зачем фильтровать, если лучшие и так будут наверху:

- скорость: оценка считается для кандидатов, всех документов не перебирают;
- счётчики по отобранному: сколько строф в каждой главе, по ним человек уточняет запрос;
- ожидания: человек считает, что слова запроса обязаны быть в ответе.

Главное

Сопоставление решает, что войдёт в выдачу, ранжирование решает порядок. Это два рычага, и их полезно держать раздельно.

Логическое соответствие: сколько слов запроса обязательны

Запрос «сон Татьяны с медведем». После конвейера три основы: «сон», «татья», «медвед». Нужные строфы: 5.XI–5.XV.

правило отбора	строф	нужных из 5
фраза «сон Татьяны» подряд	1	1: 5.XI
все три основы, И	1	0: только 5.XXIV
любые две из трёх	8	2: 5.XII, 5.XIV
любая основа, ИЛИ	81	5

Чем строже правило, тем меньше выдача и тем больше нужных строф теряется. В строфе 5.XXIV есть все три слова: Татьяна ищет медведя в соннике. Сам сон рассказан в строфах, где слова «сон» нет и Татьяна чаще названа «она».

Правило «не меньше двух из трёх» называют **минимальным совпадением**. Его порог задаётся числом или долей слов запроса.

BM25 занятия отбирает по правилу ИЛИ и доверяет порядок оценке.

Главное

Логика отбора есть такой же параметр поиска, как вес поля. На «Онегине» строгое И теряет весь сон, мягкое ИЛИ сохраняет его и отдаёт порядок ранжированию.

Фильтр отдельно, оценка отдельно

Запрос «Татьяна», и нужна глава 8. Два способа это учесть:

ранг	без условия	фильтр: глава 8	бонус: глава 8
1	3.XV	8.XXVIII	8.XXVIII
2	5.X	8.XX	8.XX
3	7.XXI	8.LI	8.LI
4	3.V	8.L	8.L
5	8.XXVIII	8.XIX	8.XIX
всего в выдаче	61	5	61

Первые пять строк совпали. Фильтр выбросил 56 строф, бонус их сохранил ниже.

Запрос делает две работы: отбирает строфы и даёт признаки для оценки.

Фильтр только отбирает: условие на поле, строфа либо проходит, либо нет.

Бонус только меняет оценку: строфы главы 8 поднимаются, остальные остаются в выдаче.

Условие «глава 8» из уточнения пользователя есть фильтр. Предпочтение «скорее глава 8» есть бонус.

Главное

Раздельные фильтр и оценка дают полный контроль над выдачей. Агент тоже должен различать «только из главы 8» и «лучше из главы 8».

Признаки релевантности предметной области

область	что решает о релевантности
рестораны	близость, ограничения в еде, вкус, цена
новости	свежесть, популярность, регион
интернет-магазин	вероятность покупки: переход, корзина, заказ
фильмы	совпадение имени, популярность, дата, оценки
вакансии	должность, уровень, зарплата, близость, отрасль
веб-поиск	место совпадения на странице, популярность, качество, спам
научные статьи	совпадение в названии и аннотации, тип публикации, год, связи цитирования
«Онегин»	первая строка, глава, персонажи строфы из графа

Две нижние строки добавлены для курса.

BM25, TF-IDF и косинус дают приличную релевантность из коробки. Хорошие признаки предметной области их обыгрывают.

Признак области берётся из структуры данных: поля, категории, даты, связи. Структуру для своей области курс построил в модуле 1: классы, свойства, граф.

Поэтому онтология возвращается в поиск ещё раз: её свойства становятся полями, фильтрами и бонусами ранжирования.

Главное

Текстовая релевантность есть основа. Порядок, который ждёт пользователь, определяют признаки его области, и их задаёт модель данных.

Метрики качества поиска: перечень

обозначение	по-английски	по-русски	что значит
P@k	Precision at k	точность в первых k	доля релевантных среди первых k документов выдачи: сколько мусора увидит читатель
R@k	Recall at k	полнота в первых k	доля найденных среди всех релевантных: сколько нужного попало в первые k
RR	Reciprocal Rank	обратный ранг	единица, делённая на позицию первого релевантного документа одного запроса
MRR	Mean Reciprocal Rank	средний обратный ранг	RR, усреднённый по всем запросам выборки: как быстро находится первый верный ответ
AP	Average Precision	средняя точность	точность на каждой позиции, где стоит релевантный документ, усреднённая по всем релевантным одного запроса
MAP	Mean Average Precision	средняя по запросам средняя точность	AP, усреднённая по всем запросам: насколько высоко стоят все верные ответы
DCG@k	Discounted Cumulative Gain	дисконтированный совокупный выигрыш	сумма градаций первых k документов, каждая со скидкой по позиции $\log_2(i+1)$
IDCG@k	Ideal DCG	идеальный DCG	DCG того же запроса при идеальном порядке: градации разметки по убыванию
NDCG@k	Normalized DCG	нормированный DCG	DCG@k / IDCG@k, от 0 до 1: учитывает и градации, и позиции, сравним между запросами

Главное

Точность и полнота не видят порядка. RR и MRR смотрят на первый верный ответ, AP и MAP на все верные. NDCG добавляет градации релевантности и скидку по позиции. Буква k есть число первых документов, которые смотрит читатель.

Выборка: 16 запросов к «Онегину»

Без размеченной выборки сравнение двух поисков есть мнение. Выборка есть список пар: запрос и строфы, которые на него отвечают, с градацией.

Градации. 2: строфа отвечает на запрос. 1: нужна для ответа или уточняет. 0: всё остальное.

запрос	релевантные строфы
дуэль Онегина и Ленского	6.XXIX, 6.XXX, 6.XXXI: 2 (сама сцена); 6.XXVI, 6.XXXII: 1
сон Татьяны с медведем	5.XI, 5.XII: 2; 5.XIII–XV: 1

Пять видов запросов.

- цитата: «мой дядя самых честных правил»;
- слова строфы: «брусничная вода»;
- одно слово: «Москва»;
- имя и событие: «дуэль Онегина и Ленского»;
- смысл своими словами: «имя героини романа».

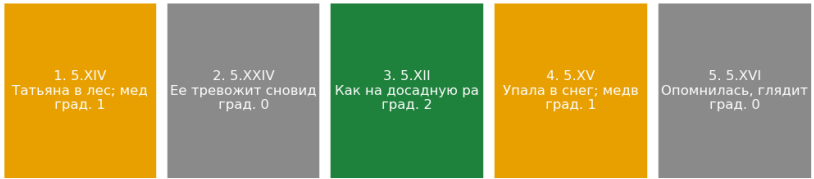
Разметка по смыслу, без оглядки на слова: сама сцена дуэли размечена градацией 2, хотя слова «дуэль» в ней нет.

Главное

Запросы разных видов нужны, чтобы выборка нашла границу канала. Запрос, повторяющий первую строку строфы, найдётся всегда и ничего не измеряет.

Четыре метрики на выдаче «сон Татьяны»

«Сон Татьяны с медведем»: релевантных 3 из 5, всего релевантных 5

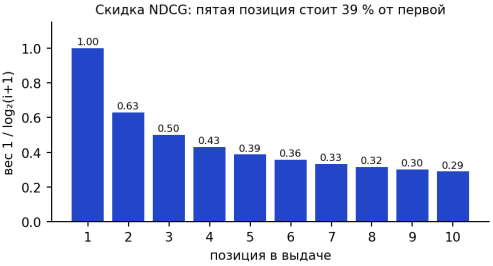


метрика	смысл	на этой выдаче
точность@5	доля релевантных среди первых пяти	3 / 5 = 0,6
полнота@5	доля найденных среди всех релевантных	3 / 5 = 0,6
обратный ранг	единица на позицию первого релевантного	1 / 1 = 1,0
средняя точность AP	точность на позициях релевантных, среднее по всем пяти	0,57

Главное

Точность и полнота не видят порядка. MRR смотрит на первый верный ответ, MAP на все. Главная строфа сна, 5.XI «И снится чудный сон Татьяне», стоит только девятой и в пятёрку не попала.

Нормированный выигрыш со скидкой (NDCG)



Выигрыш позиции есть градация строфы. Скидка есть $\log_2(i+1)$: первая позиция без скидки, вторая делится на 1,58, третья на 2. Дисконтированный совокупный выигрыш (DCG) складывает выигрыши со скидками:

$$DCG@k = \sum_{i=1}^{k} \frac{g_i}{\log_2(i+1)}$$

Идеальный выигрыш (IDCG@k) есть DCG идеального порядка: градации из разметки по убыванию. Нормированный выигрыш со скидкой (NDCG@k) есть их отношение, от 0 до 1, и его можно сравнивать между запросами с разным числом релевантных строф.

Строфа с градацией 2 ценнее строфы с градацией 1. Та же строфа на пятой позиции стоит в 2,6 раза меньше, чем на первой.

Главное

Нормированный выигрыш со скидкой (NDCG) соединяет три вещи: найдена ли строфа, насколько она релевантна, на какой позиции стоит. Главная метрика задания.

Нормированный выигрыш NDCG@3 на «Онегине»: дуэль и сон

Обозначения: DCG есть дисконтированный совокупный выигрыш, IDCG есть идеальный выигрыш, NDCG есть нормированный выигрыш со скидкой.

Дуэль Онегина и Ленского. Релевантны: 6.XXIX, 6.XXX, 6.XXXI с градацией 2 (сама сцена), 6.XXVI и 6.XXXII с градацией 1. Выдача: 6.XXVI, 6.IX, 2.XV, градации 1, 0, 0.

$$DCG@3 = \frac{1}{1} = 1{,}000$$

$$IDCG@3 = 2 + 1{,}262 + 1 = 4{,}262$$

$$NDCG@3 = 1{,}000/4{,}262 = 0{,}235$$

Найден разговор о дуэли, сцена не найдена.

Сон Татьяны с медведем. Релевантны: 5.XI, 5.XII с градацией 2, 5.XIII, 5.XIV, 5.XV с градацией 1. Выдача: 5.XIV, 5.XXIV, 5.XII, градации 1, 0, 2.

$$DCG@3 = 1 + 0 + \frac{2}{2} = 2{,}000$$

$$IDCG@3 = 2 + 1{,}262 + 0{,}5 = 3{,}762$$

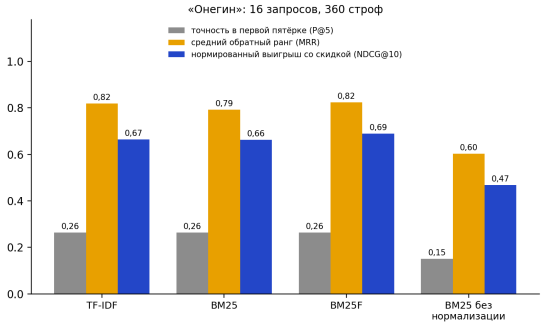
$$NDCG@3 = 2{,}000/3{,}762 = 0{,}532$$

Строфа с градацией 2 найдена третьей: на первой позиции она дала бы вдвое больше.

Главное

Два запроса о событиях, два числа: 0,235 и 0,532. Числа различают «нашёл разговор о событии» и «нашёл событие не первым», и глазами эту разницу оценить труднее.

Метрики на «Онегине»: конвейер важнее формулы



Шестнадцать запросов, четыре варианта поиска.

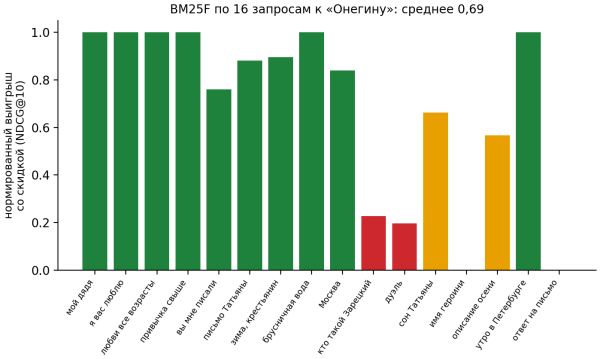
Три ранжирования идут вровень: TF-IDF 0,67, BM25 0,66, BM25F 0,69 по нормированному выигрышу со скидкой (NDCG@10). Строфы одной длины, насыщению и поправке на длину почти нечего исправлять.

Без стоп-слов и основ нормированный выигрыш падает до 0,47. Склейка словоформ даёт больше, чем выбор формулы.

Главное

Таблица читается по различиям между строками. На корпусе с документами разной длины BM25 выигрывает, и это проверяется той же таблицей.

По запросам: единицы и нули



Зелёные: цитаты и слова строф. «Мой дядя самых честных правил», «брусничная вода»: единица.

Жёлтые: найдено частично. Сон Татьяны 0,66, описание осени 0,57.

Красные: событие и смысл своими словами. Дуэль 0,20, Зарецкий 0,23, имя героини и ответ на письмо ноль.

Главное

Средний нормированный выигрыш со скидкой (NDCG@10) 0,69 складывается из единиц и нулей.

Граница канала видна только по запросам: слова находятся, смысл без слов нет.

Сбор выборки: правила

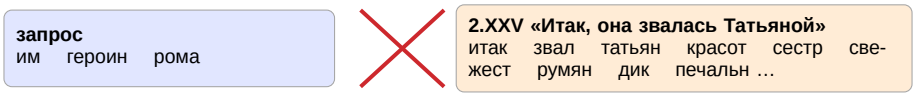
1. Запросы из вопросов, ради которых строится поиск: вопросы исследователя из задания лекции 1 идут первыми.
2. Разные формы: термин, номер, вопрос целиком, перефразировка, запрос без слов документа. Без последних выборка не найдёт границу.
3. Разметка по смыслу: документ релевантен, если отвечает на вопрос, независимо от совпадения слов.
4. Три градации. Релевантных на запрос от одного до пяти.
5. Выборка хранится в `kg/queries.csv` рядом с корпусом и не меняется между сравнениями. Новый запрос дописывается, старые не правятся.
6. Метрики считает скрипт одной командой, и таблица в отчёте получена этим скриптом.

Та же выборка в лекции 6 измерит полноту векторного поиска, в лекции 7 покажет, где граф отвечает лучше текста, в лекции 8 проверит, что гибрид не хуже лучшего канала.

Главное

Выборка есть самый долгоживущий артефакт модуля 2: четыре лекции измеряются на ней.

Синонимия: «имя героини романа»

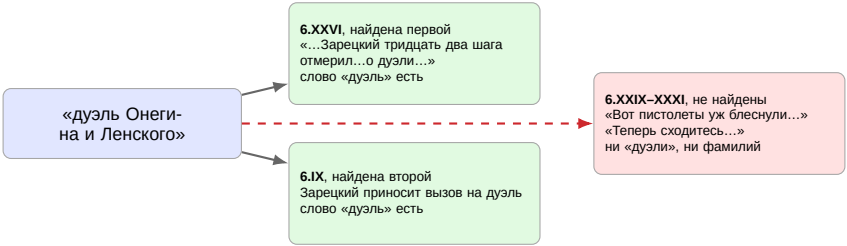


Выдача по словам «героиня» и «роман»: 3.X «Воображаясь героиней», 2.XIII, 2.XVI. Строфа, где героиню называют по имени, не найдена. Оценка есть сумма вкладов совпавших слов, и если совпавших нет, она равна нулю при любых k_1, b и весах полей.

Главное

Поиск по словам находит только совпадения. Синонимия есть его главная граница, и никакой параметр её не сдвигает.

Событие находится там, где о нём говорят



То же с вопросом «ответ Онегина на письмо Татьяны»: найдены строфы со словами «ответ» и «письмо», объяснение в саду, где нет ни того, ни другого слова, не найдено. Читатель помнит смысл и забывает слова.

Главное

Разговор о событии и сцена события написаны разными словами. Поиск по словам находит разговор.

Смысл без слов: три провала на «Онегине»

имя героини романа
найдено: 3.X «Воображаясь героиней», 2.XIII, 2.XVI
ответ 2.XXV «Итак, она звалась Татьяной»: ни «имени», ни «героини»

нормированный выигрыш (NDCG) 0

описание осени
найдено: 5.I «В тот год осенняя погода» первой
ответ 4.XL «Уж небо осенью дышало» пятой: слова «описание» в стихах нет

нормированный выигрыш (NDCG) 0,57

ответ Онегина на письмо Татьяны
найдено: «Ответа нет», «нет ответа», само письмо
ответ 4.XII «Вы ко мне писали, не отпирайтесь»: ни «ответа», ни «письма»

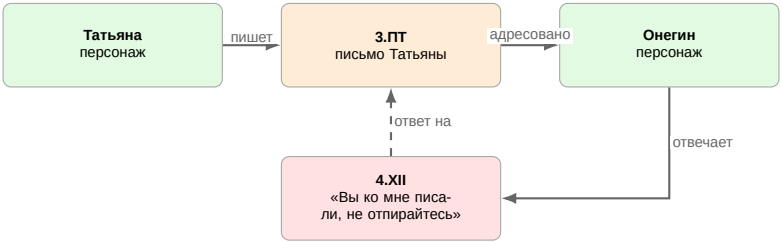
нормированный выигрыш (NDCG) 0

Читатель помнит, о чём строфа, и забывает её слова. Запрос называет смысл, строфа записана другими словами, и у трёх провалов одна причина.

Главное

Вопрос о содержании, заданный своими словами, есть главный провал поиска по словам. Его закроют векторы в лекции 6, и эти три запроса остаются в выборке.

Связи: письмо и ответ на него

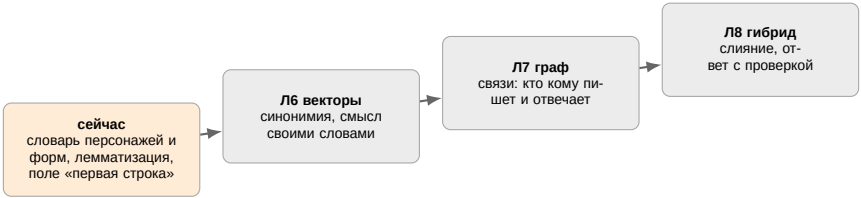


Запрос «ответ Онегина на письмо Татьяны» находит строфы со словами «ответ» и «письмо»: 8.XXXIII «Ответа нет», 3.XXXVI «нет ответа», само письмо. Строфа 4.XII, где Онегин отвечает, не найдена: в ней «писали» вместо «письмо», и нет слова «ответ». Связь «ответ на письмо» в тексте не записана, её знает читатель.

Главное

Связи между документами есть граница иного рода: здесь не хватает рёбер. Текст их не содержит, и лекция 7 даст граф, по которому такой вопрос проходит обходом.

Что помогает сейчас и что сделают лекции 6–8



Словарь «героиня → Татьяна, имя → звалась» поднимает строфу 2.XXV на третье место по запросу «имя героини романа». Словарь есть знание о предметной области, записанное заранее, и его эффект проверяется той же выборкой.

Главное

Поиск по словам остаётся первым каналом: в гибриде, как точка входа в граф, как быстрый отбор кандидатов. Его границы измерены, и следующий канал добавляется осмысленно.

Порядок показа на «Онегине»

Команда. `python3 demo_onegin.py` печатает весь показ. `--live` принимает запросы по ходу показа: запрос, выдача с вкладом каждой основы.

1. Ципф: рисунок и доля однократных словоформ, одна минута.
2. Точная строка: «мой дядя», отрыв вдвое, прогноз перед запуском.
3. Имя и событие: «дуэль», сцена не найдена.
4. Ловушка конвейера: «кто такой Зарецкий» до и после.
5. Смысл без слов: три провала.
6. Таблица метрик и гонка.

Запросы по ходу показа. Строфа называется своими словами, лектор вводит запрос. Если строфа найдена, видно, какие слова совпали. Если нет, видно, что общих основ нет. Это и есть граница канала, показанная на материале, который слушатели знают лучше лектора.

Прогнозы. Перед «дуэлью»: найдётся ли сцена? Перед «именем героини»: какая строфа будет первой?

Главное

Живой пример отличается от сквозного тем, что запросы задаются по ходу показа, и ответ виден раньше, чем лектор его объяснит.

Запросы по ходу показа

```
$ python3 demo_onegin.py --live
> мой дядя самых честных правил
  основы: ['мо', 'дяд', 'сам', 'честн', 'правил']
   21.59  1.I       Мой дядя самых честных правил,
          вклад: дяд 4.38, честн 4.38, правил 3.75 ...
   10.94  1.LII     Вдруг получил он в самом деле
> имя героини романа
  основы: ['им', 'героин', 'рома']
    9.08  3.X       Воображаясь героиней
    ...   2.XXV «Итак, она звалась Татьяной» — не найдена
```

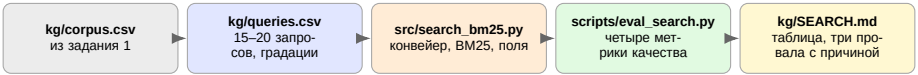
Строфа называется своими словами, лектор вводит запрос. Если найдена, видно, какие основы совпали. Если нет, видно, что общих основ нет.

Это граница канала, показанная на материале, который слушатели знают лучше лектора. Запросы, которые провалились, записываются в выборку для лекции 6.

Главное

Живой пример отличается от сквозного тем, что запросы задаются по ходу показа, и ответ виден раньше, чем лектор его объяснит.

Задание 4: сдаётся измерение



Метрики: точность в первой пятёрке (P@5), полнота в первой пятёрке (R@5), средний обратный ранг (MRR), нормированный выигрыш со скидкой (NDCG@10). Порядок: сначала выборка, потом метрики. Выборка, собранная после выдачи, измеряет только то, что уже найдено. Проверка `scripts/check_l5.py`, 21 пункт. Образец на корпусе «Правила зачёта» в стартовом наборе.

Главное

Та же выборка послужит заданиям лекций 6–8. Три провала с причинами суть то, что оценивает человек.

Мини-практика и порядок работы

Мини-практика (первый час работы).

1. Повторить показ на «Онегине»: `python3 onegin/demo_onegin.py`, затем свои запросы через `--live`.
2. Для одного запроса своего корпуса напечатать вклад каждого слова в оценку BM25 для первых трёх документов.
3. Посчитать нормированный выигрыш со скидкой (NDCG@3) вручную для этой выдачи и сверить с функцией.

Порядок работы над заданием.

1. Скопировать `search_bm25.py` в `src/`, подключить свой корпус и его поля.
2. Собрать `kg/queries.csv`: пять вопросов исследователя, затем 10–15 новых разной формы. Разметить по смыслу.
3. Запустить `eval_search.py` для четырёх вариантов: два конвейера × два ранжирования.
4. Найти в таблице по запросам три провала, объяснить причину каждого.
5. Записать решения в `SEARCH.md` и `diary.md`.
6. Прогнать `check_l5.py` до 21 из 21.

Главное

Сначала выборка, потом метрики, потом провалы. Выборка, собранная после того, как увидена выдача, измеряет только то, что уже найдено.

Критерии и что проверяет скрипт

Критерии программы. Тестовая выборка размечена. Метрики воспроизводятся скриптом. Три провала объяснены.

Скрипт `check_l5.py`, 21 пункт, среди них:

- `queries.csv`: не меньше 15 запросов, релевантные из корпуса, градации 1–2, не меньше трёх запросов без слов из названия релевантного документа;
- `search_bm25.py`: индекс строится, конвейер со стеммингом, параметры k_1 и b задаются;
- `eval_search.py`: печатает четыре метрики, числа совпадают с таблицей в `SEARCH.md`;
- `SEARCH.md`: таблица с четырьмя вариантами, три провала с причиной.

Типичные ошибки.

- запросы, повторяющие названия документов: выборка ничего не измеряет;
- метрика без *k*: «точность 0,4» ничего не значит;
- провал без причины: «не нашёл» не есть объяснение;
- конвейер запроса отличается от конвейера индекса: пустые выдачи;
- стоп-слово «не» в списке: смысл требований теряется;
- таблица в отчёте получена не скриптом и не воспроизводится.

Главное

Скрипт проверяет форму, лекция проверяет смысл: причина провала и чтение таблицы суть то, что оценивает человек.

Упражнения

Семь упражнений в `exercises_L5.md`, с ответами, не оцениваются.

1. Построить инвертированный индекс для трёх строф вручную и выполнить булев запрос.
2. Посчитать IDF для слов «Онегин» и «дядя» в «Онегине» и объяснить, почему имя героя весит меньше.
3. Показать на мини-примере, при каком k_1 строфа с двумя вхождениями слова обгонит строфу с одним.
4. Для выдачи из пяти строф с заданными градациями посчитать точность в первой пятёрке (P@5), обратный ранг (RR), среднюю точность (AP) и нормированный выигрыш со скидкой (NDCG@5).
5. Привести два запроса к своему корпусу, которые поиск по словам не найдёт, и назвать причину.
6. Добавить к запросу «имя героини романа» словарь персонажей и проверить, что изменилось в таблице метрик.
7. Объяснить, почему средний обратный ранг (MRR) может быть высоким при низкой точности в первой пятёрке (P@5).

Главное

Упражнения 3 и 4 повторяют экзаменационные вопросы 8 и 9.

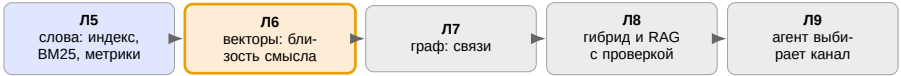
Итоги занятия

1. Поиск есть сбор контекста, первая часть агентного цикла. Модуль 1 дал проверку, модуль 2 даёт поиск.
2. Мешок слов и инвертированный индекс: быстро, потому что читаются только списки слов запроса.
3. Конвейер решает, что считать словом, и влияет на метрики сильнее формулы.
4. BM25 складывает редкость и частоту с насыщением и поправкой на длину. Вклад каждого слова виден: выдача объяснима.
5. Качество измеряется на размеченной выборке. Нормированный выигрыш со скидкой (NDCG) учитывает градации и позиции.
6. Границы измерены: синонимия, смысл своими словами, связи между строфами. Их закроют лекции 6–8 на той же выборке.

Главное

Поиск по словам находит документы со словами запроса, упорядочивает их по редкости и частоте, и качество порядка измеряется на выборке, без которой любое сравнение поисков есть мнение.

К следующему занятию: векторный поиск



Принести. `kg/queries.csv` с 15–20 запросами и таблицу метрик BM25 на своём корпусе. Три запроса, где поиск по словам провалился, с причиной. Установленные `sentence-transformers` и `faiss-cpu`, одна модель векторизации скачана заранее.

Статья недели. Reimers, Gurevych. Sentence-BERT, 2019, разделы 1–3. Вопрос: чем раздельное кодирование запроса и документа отличается от совместного и почему первое годится для индекса.

Главное

Запросы «имя героини романа» и «ответ Онегина на письмо Татьяны» ждут лекцию 6: та же выборка покажет, закрывают ли векторы синонимию.

Дополнение. Задача редактора

что поиск по словам даёт на положении о рецензировании

Задача редактора: корпус и вопросы

Положение о рецензировании, 31 запись: пять разделов, одиннадцать терминов, пятнадцать требований. Поля «название» и «формулировка».

пункт 6.5 (R65)	**Принятие решения.** Редакционная коллегия принимает решение на основании не менее двух рецензий и ответа авторов.
пункт 6.6 (R66)	**Срок рецензирования.** Рецензия представляется в течение 21 дня с момента назначения рецензента.

Сквозной пример курса: редактор сборника решает, какие из восьми статей P1–P8 выносить на решение. После модуля 1 ответ агента: готовы статьи P1, P2, P7, у остальных назван нарушенный пункт.

Что требуется от поиска. Найти пункты положения по вопросу редактора, заданному своими словами, и сообщить агенту, насколько найденному верить.

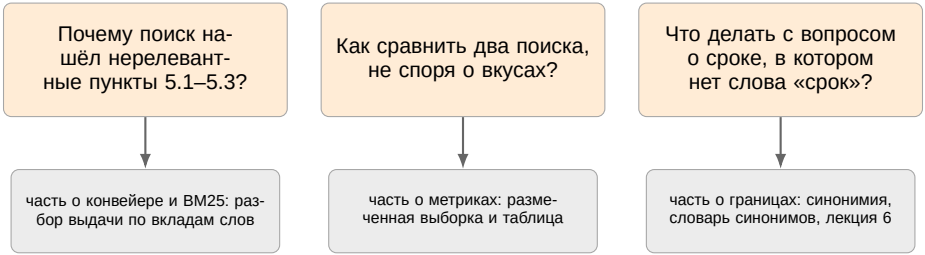
Выборка. 16 запросов: пять вопросов редактора из лекции 1 и одиннадцать вопросов, которые редактор и автор задают положению в работе. У каждого запроса есть пункты-ответы с градацией.

Дальше те же понятия, что на «Онегине», показаны на этом корпусе.

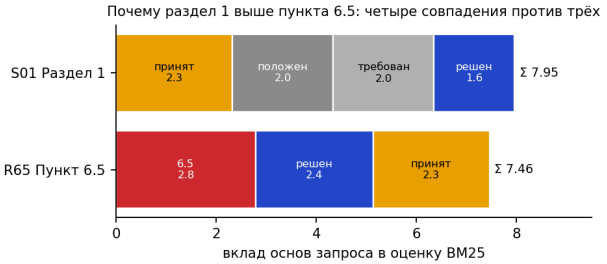
Главное

На «Онегине» механизм виден сам по себе. На положении видно, что он даёт агенту в задаче, ради которой строится курс.

Три вопроса, оставшиеся после лекции 1



Объяснение выдачи: вклад каждого слова



Запрос: «на какие положения опирается требование 6.5 о принятии решения».

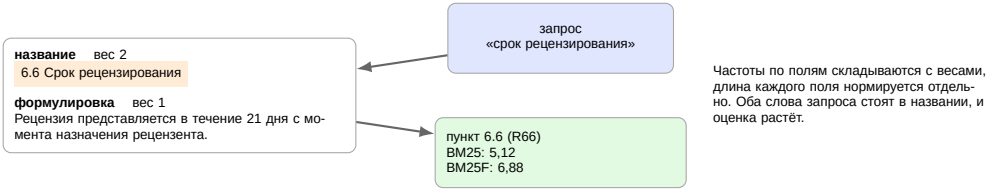
В разделе 1 совпали четыре основы: «положение устанавливает требования к принятию решений». В пункте 6.5 три: «принятии» из запроса дало «принят», «принимает» в пункте дало «принима», стеммер их не склеил.

BM25F с полем названия возвращает 6.5 на первое место: «принятие решения» стоит в названии пункта.

Главное

У каждой строки выдачи есть объяснение по вкладам слов. Это сильная сторона канала: выдачу можно разобрать до основ.

Поля документа: BM25F



Поля суть структура, известная до поиска: название, тип записи, раздел. В корпусе области поле «тип» отличает определение от теоремы.

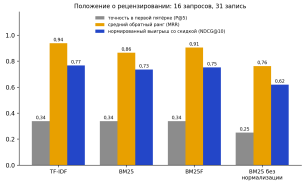
Главное

Первая точка, где структура из модуля 1 помогает словам: без онтологии и без графа, одними полями.

Таблица метрик на выборке положения о рецензировании

вариант	точность в первой пятёрке, P@5	полнота в первой пятёрке, R@5	средний обратный ранг, MRR	средняя точность по запросам, MAP	нормированный выигрыш со скидкой, NDCG@10
TF-IDF, косинус	0,338	0,665	**0,938**	0,631	**0,768**
BM25	0,338	0,665	0,865	0,617	0,735
BM25F, название ×2	0,338	0,665	0,906	**0,633**	0,753
BM25 без стоп-слов и основ	0,250	0,512	0,762	0,478	0,619

Шестнадцать запросов, конвейер со стоп-словами и основами в трёх первых строках, $k_1 = 1{,}5$, $b = 0{,}75$.



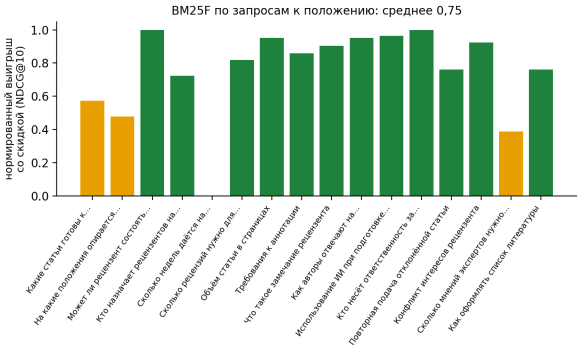
Самое большое различие между первой и последней строкой: нормализация словоформ поднимает нормированный выигрыш со скидкой (NDCG@10) на 0,12. Конвейер важнее формулы.

Три ранжирования идут вровень. На 31 коротком документе насыщение и длина почти не работают. На тысячах документов картина другая, и это проверяется той же таблицей.

Главное

Таблица метрик читается по различиям между строками. Полнота@5 в 0,67 означает, что треть нужного поиск по словам не находит.

Среднее скрывает, по запросам видно



Зелёные: точный термин и номер: «рецензент из организации авторов» (q03), «ответственность за содержание» (q12).

Жёлтые: найдена точка входа, зависимости и перефразировки нет: «на что опирается пункт 6.5» (q02), «сколько мнений экспертов нужно» (q15).

Красные: синонимия, «сколько недель даётся на подготовку отзыва» (q05), ноль.

Средний обратный ранг (MRR) 0,9 при точности в первой пятёрке (P@5) 0,34: первый ответ почти всегда верный, остальное наполовину мусор.

Главное

Из таблицы по запросам берётся граница канала: красные столбцы суть задачи для лекций 6 и 7.

Синонимия: ни одной общей основы



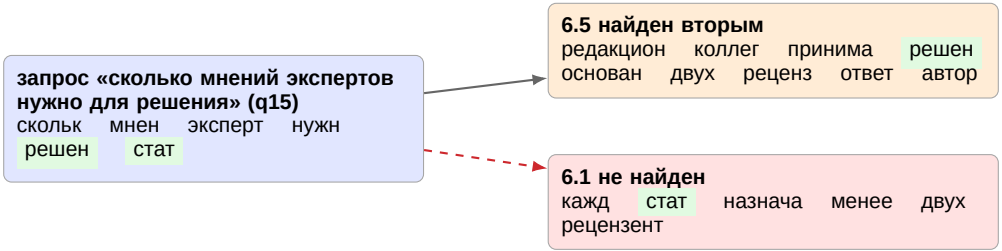
отзыв $\neq$ рецензия недели $\neq$ 21 день «даётся на подготовку» $\neq$ «представляется в течение»

Выдача по слову «подготовка»: пункт об ИИ-инструментах. Оценка есть сумма вкладов совпавших слов, и если совпавших нет, она равна нулю при любых k_1, b и весах полей. Редактор именно так и спрашивает.

Главное

Поиск по словам находит только совпадения. Синонимия есть его главная граница, и никакой параметр её не сдвигает.

Перефразировка: половина слов совпала

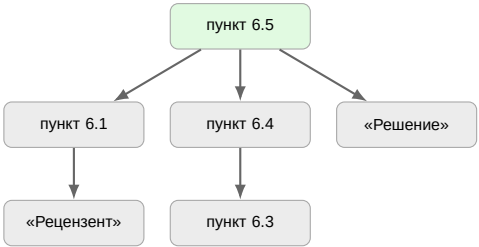


«Мнение эксперта» и «рецензент» суть одно и то же для редактора и разные слова для индекса. Пункт 6.5 найден по общим словам «решение» и «статья», пункт 6.1 потерян: единственное общее слово «статья» стоит в восемнадцати записях и почти ничего не весит.

Главное

Перефразировка есть синонимия на уровне фразы: часть слов совпала, выдача неполная, и нормированный выигрыш со скидкой (NDCG@10) равен 0,39 вместо единицы.

Связи и формулы: две границы иного рода



Поиск находит пункт 6.5: в нём слова запроса. Четырнадцать положений, от которых 6.5 зависит, по словам не найти: в их тексте нет слов запроса. Лекция 3 получила их машиной вывода, лекция 7 даст обход графа.

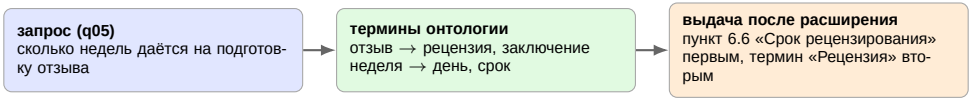
Формулы. Запрос «$a^2 + b^2 = c^2$» распадается на буквы a, b, c и находит формулу Герона, где они есть, с уверенной оценкой 11. Теорема Пифагора записана словами «квадрат гипотенузы равен сумме квадратов катетов» и не найдена.

Одна формула записывается десятью способами. В SciLib формулы индексируются по структуре выражения, в курсе этот канал не рассматривается. Правило для корпуса: каждая формула сопровождается словесной формулировкой.

Главное

Связи нужны для вопроса 2 редактора, и у индекса нет рёбер. Это вопрос к каналу, и его закроет граф.

Расширение запроса словарём онтологии



На выборке положения о рецензировании средний обратный ранг (MRR) растёт с 0,906 до 0,969, нормированный выигрыш со скидкой (NDCG@10) с 0,753 до 0,816. Расширение добавляет и шум: эффект каждого словаря измеряется той же выборкой до и после.

Ещё две дешёвые меры: формулы сопровождаются словесной формулировкой в поле, поле «тип» отсекает теоремы от определений. Структура из модуля 1 возвращается в поиск словарём и полями.

Главное

Онтология помогает поиску по словам уже сейчас, без векторов и графа. Эффект проверяется выборкой, не на глаз.

Инструмент поиска входит в агента с числом

```
search_words:
  "Поиск по словам (BM25F) по положению о рецензировании.
   Точность@5 на выборке из 16 запросов: 0.338.
   Находит документы, где есть слова запроса.
   Синонимов и связей не знает."

[1] search_words("Сколько недель даётся на подготовку отзыва")
    <- пункт 8.2, раздел 1, термин «ИИ-инструмент»
       (все по слову «подготовка»)
[2] ответ модели:
[не найдено по словам] Нормы о сроке среди найденного нет.
Вопрос нужно задать иначе или другим каналом.
```

В описании инструмента три вещи: измеренная точность, что находит, чего не находит. Инструкция требует помечать найденное «найдено по словам» с рангом и сообщать о пустой выдаче честно.

Изменились три компонента: инструмент получил число, контекст границу, верификатор пометку для сверки с протоколом. В лекции 6 рядом встанет `search_vectors` с числом на той же выборке.

Главное

Честное «не найдено» возможно, потому что граница инструмента измерена и модель о ней знает. Канал входит в агентный цикл как инструмент сбора контекста.

Прогон на вопросе 2

```
[1] модель вызвала search_words('query': 'На какие положения опирается требование 6.5
    о принятии решения', 'k': 5)
    <- ["id": "R65", "оценка": 10.498, "текст": "6.5 Принятие решения. Редакционная коллегия
        принимает решение на основании не менее двух рецензий и ответа авторов."…
[2] ответ модели:
Требование 6.5 (R65): редколлегия принимает решение на основании не менее двух рецензий
и ответа авторов [найдено по словам: ранг 1]. Раздел 1 (S01) задаёт область применения
[найдено по словам: ранг 2]. Какие положения стоят за 6.5 (6.1, 6.4, термин «Решение»),
по словам не найти: нужен граф зависимостей.
```

Что правильно. Оба документа ответа есть в выдаче, у каждого ранг. Зависимости не выдуманы, названы честно как то, чего поиск по словам не даёт.

Что проверяет верификатор. Каждая пометка «найдено по словам: ранг *r*» сверяется с протоколом: документ на позиции *r* выдачи. Пометка без документа в выдаче есть выдумка.

Главное

Ответ агента читается по пометкам: что найдено, где, с каким рангом. Протокол вызова есть доказательство каждой пометки.

Что поиск по словам даёт на задаче редактора

Что даёт.

- Пункт по номеру и термину находится сразу: «рецензент из организации авторов» и «ответственность за содержание» дают нормированный выигрыш со скидкой (NDCG), равный единице.
- Первый ответ почти всегда верный: средний обратный ранг (MRR) 0,91.
- Каждая строка выдачи объяснима по вкладам слов, и агент может пометить её «найдено по словам» с рангом.
- Измеренная точность записывается в описание инструмента, и агент знает, насколько ему верить.

Чего не даёт.

- Вопрос о сроке, заданный без слова «срок», остаётся без ответа: синонимия.
- Пункты, на которые опирается 6.5, по словам не находятся: связи лежат в графе зависимостей и онтологии модуля 1.
- Треть нужных пунктов не попадает в первую пятёрку: полнота@5 равна 0,67.

Что уже помогает. Словарь синонимов из онтологии поднимает средний обратный ранг (MRR) с 0,91 до 0,97, поле названия поднимает пункт 6.5 на первое место.

Главное

На задаче редактора поиск по словам есть быстрый и объяснимый первый канал с измеренной границей. Онтология модуля 1 возвращается в него словарём, граф лекции 7 закроет связи.

Литература

1. Manning C. D., Raghavan P., Schütze H. Introduction to Information Retrieval. Cambridge University Press, 2008. Главы 1, 2, 6, 8, 11. Статья недели.
2. Robertson S., Zaragoza H. The Probabilistic Relevance Framework: BM25 and Beyond. Foundations and Trends in Information Retrieval, 3(4), 2009. Вывод BM25 и BM25F.
3. Robertson S. E., Walker S., Jones S., Hancock-Beaulieu M., Gatford M. Okapi at TREC-3. 1994. Первое появление BM25.
4. Järvelin K., Kekäläinen J. Cumulated gain-based evaluation of IR techniques. ACM TOIS, 20(4), 2002. Дисконтированный и нормированный выигрыш, DCG и NDCG.
5. Porter M. F. An algorithm for suffix stripping. Program, 14(3), 1980. Snowball: snowballstem.org, русский стеммер.
6. Грейнджер Т., Тернбулл Д., Ирвин М. Поиск на основе искусственного интеллекта / пер. с англ. И. Л. Люско. М.: ДМК Пресс, 2025. 586 с. Глава 1: поиск на основе ИИ, намерение пользователя, ступени поиска, генерация с опорой на поиск. Глава 2: структура текста, распределительная семантика и эмбеддинги, многозначность, уровни знаний о предметной области, контент и сигналы. Глава 3: векторы запроса и документа, функции оценки, сложение и умножение признаков, сопоставление и ранжирование.
7. Lin J. A proposed conceptual framework for a representational approach to information retrieval. SIGIR Forum, 55(2), 2021. Разреженные и плотные представления в одной рамке, мост к лекции 6.
8. Kamphuis C., de Vries A. P., Boytsov L., Lin J. Which BM25 do you mean? A large-scale reproducibility study of scoring variants. ECIR 2020. Варианты формулы и почему они дают одни результаты.

Приложение А. Шпаргалка формул

что	формула	смысл
IDF	$\log \frac{N}{\text{df}}$; в BM25 $\log\left(\frac{N - \text{df} + 0{,}5}{\text{df} + 0{,}5} + 1\right)$	редкость слова в корпусе
TF-IDF	$f \cdot \text{IDF}$	часто здесь, редко вообще
косинус	$\frac{\sum q_w d_w}{\|q\| \, \|d\|}$	угол между векторами
BM25	$\sum_w \text{IDF}(w) \, \frac{f(k_1 + 1)}{f + k_1(1 - b + b\, dl/avgdl)}$	насыщение и длина
BM25F	то же с $\tilde{f} = \sum_p$ вес$_p f_p$ / норма$_p$	поля с весами
точность@k	релевантных в первых k / k	доля мусора
полнота@k	найденных в первых k / всех релевантных	доля потерянного
обратный ранг (RR), средний обратный ранг (MRR)	1/позиция первого релевантного, среднее	первый верный ответ
средняя точность (AP), её среднее по запросам (MAP)	среднее точностей на позициях релевантных	все верные ответы
дисконтированный выигрыш (DCG@k)	$\sum_{i \le k} g_i / \log_2(i + 1)$	выигрыш со скидкой
нормированный выигрыш со скидкой (NDCG@k)	DCG@k / IDCG@k, IDCG есть идеальный выигрыш	доля от идеала

Приложение Б. Словарь лекции

мешок слов документ как множество слов с частотами, без порядка

разреженный вектор вектор в пространстве словаря, почти все координаты нули

инвертированный индекс словарь «слово → документы с частотами»

список вхождений документы одного слова в индексе

df, N число документов со словом, число всех документов

токенизация разбиение текста на слова и числа

стоп-слова частые слова, исключаемые из индекса

стемминг отсечение окончаний по правилам

лемматизация приведение к словарной форме по словарю

конвейер индексации токены, нормализация, стоп-слова, основы

насыщение замедление роста веса с частотой, k_1

нормализация длины поправка на длину документа, b

BM25F BM25 с полями документа и весами полей

тестовая выборка запросы с размеченными релевантными документами

градация релевантности 0, 1, 2: не отвечает, уточняет, отвечает

объединение выдач разметка объединённых выдач нескольких поисков

точность@k, полнота@k доля релевантных в k, доля найденных

MRR, MAP средний обратный ранг, средняя средняя точность

NDCG@k выигрыш со скидкой, делённый на идеальный

синонимия, перефразировка один смысл, разные слова и фразы

Приложение B. Вопросы для самопроверки

1. Почему инвертированный индекс быстрее перебора документов и от чего зависит время ответа?
2. Что такое IDF и почему слово «6.5» весит больше слова «статья» в положении о рецензировании?
3. Какие две слабости TF-IDF исправляет BM25 и какими параметрами?
4. Что происходит с выдачей при $k_1 \to 0$ и при $b = 0$?
5. Чем BM25F отличается от BM25 на документе с названием и текстом?
6. Почему стемминг поднял метрики на корпусе положения о рецензировании и какие две ошибки он допустил?
7. Чем точность@5 отличается от полноты@5 и что обе не видят?
8. Когда средний обратный ранг (MRR) предпочтительнее средней точности по запросам (MAP)?
9. Посчитайте нормированный выигрыш со скидкой (NDCG@3) для выдачи с градациями 0, 2, 1 при идеальных 2, 1, 0.
10. Назовите три причины провала поиска по словам и для каждой запрос из своего корпуса.
11. Почему выборка собирается до того, как увидена выдача?
12. Что должно стоять в описании инструмента поиска для модели и зачем?

Приложение Г. Расчёт нормированного выигрыша со скидкой (NDCG@3) по шагам

Дано. Выдача из трёх документов с градациями g_1, g_2, g_3 и разметка запроса.

Шаг 1. Выписать градации выдачи по позициям. Пример, запрос о пункте 6.5: 2, 0, 0.

Шаг 2. Скидки: $\log_2 2 = 1$, $\log_2 3 = 1{,}585$, $\log_2 4 = 2$.

Шаг 3. Дисконтированный выигрыш $DCG@3 = g_1/1 + g_2/1{,}585 + g_3/2$. Пример: $2 + 0 + 0 = 2{,}000$.

Шаг 4. Идеальные градации: все градации разметки по убыванию, первые три. Пример: 2, 2, 2.

Шаг 5. Идеальный выигрыш $IDCG@3$ той же формулой. Пример: $2 + 1{,}262 + 1{,}000 = 4{,}262$.

Шаг 6. Нормированный выигрыш $NDCG@3 = DCG/IDCG$. Пример: $0{,}469$.

Второй пример для самопроверки. Выдача с градациями 0, 2, 1, разметка содержит градации 2, 1 и больше ничего.

$DCG@3 = 0 + 2/1{,}585 + 1/2 = 1{,}262 + 0{,}5 = 1{,}762$.

Идеальные: 2, 1, 0.
$IDCG@3 = 2 + 1/1{,}585 + 0 = 2{,}631$.

$NDCG@3 = 1{,}762/2{,}631 = 0{,}670$.

Частые ошибки. Скидка на первой позиции равна 1. Идеальный порядок берётся из разметки. При k больше числа релевантных идеальные градации дополняются нулями.