Векторный поиск: плотные представления, контрастивное обучение и поиск ближайших соседей

О. М. Атаева А. П. Халов

Осень 2026

Курс «От интеллектуального поиска к интеллектуальным агентам», ВМК МГУ. Модуль 2, занятие 2

Где остановился поиск по словам

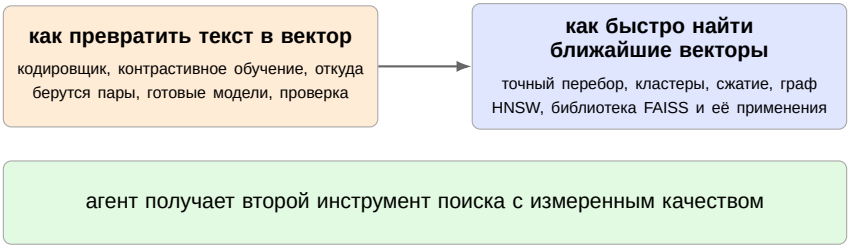
На занятии 5 поиск BM25F по «Онегину» дал нормированный выигрыш со скидкой 0,69. Он хорошо находит цитаты и редкие слова и проваливается там, где смысл запроса и документа совпадает при разных словах.

- **Синонимия.** Вопрос «Сколько недель даётся на подготовку отзыва» не находит пункт 6.6 «Срок рецензирования» положения о рецензировании.
- **Перефразировка.** Вопрос «Сколько мнений экспертов нужно для решения по статье» не находит пункт о числе рецензий.
- **Формула.** Запрос $a^2 + b^2 = c^2$ не находит теорему Пифагора, записанную словами.

Вопрос «ответ Онегина на письмо Татьяны» требует знать связь между строфами. Его мы оставим графу лекции 7.

Вопрос лекции. Как искать по смыслу, когда слова запроса и документа расходятся, и как делать это быстро на миллионах документов?

План лекции



Пример прежний: 360 строф «Евгения Онегина» и 16 размеченных запросов. Для обучения моделей понадобится ещё корпус ParaPhraser: 9151 пара русских новостных заголовков, которые люди разметили как перефразирования, пары близкого смысла и пары разного смысла. Выводы мы проверим и на двух корпусах курса.

Поиск по словам не видит близких слов



Строфа 5.II «Зима!.. Крестьянин, торжествуя» в двух представлениях. Сверху её вектор в индексе занятия 5: 4881 измерение, по одному на основу слова, и только 43 ненулевых. Снизу вектор той же строфы у модели BGE-M3: 1024 числа, и все они ненулевые.

запрос	строф	какие
«дуэль»	2	вызов, ожидание у плотины
«выстрел»	1	6.XXX
«пистолет»	8	среди них 6.XXIX, 6.XXX
«поединок»	0	ни одной

У разреженного вектора своя ось для каждой основы слова, и оси между собой не связаны. Запрос «поединок» к сцене дуэли не нашёл ничего по двум причинам. Сама сцена написана без этого слова. Две строфы, где слово есть, «Пред поединком Ольгу видеть» и «Убив на поединке друга», потерял стеммер: этим формам он дал основу «поединк», запросу основу «поединок».

Плотный вектор находит «поединок»

Запрос «поединок», модель BGE-M3, ближайшие строфы:

место	строфа	косинус
1	6.IX «То был приятный, благородный», вызов	0,459
2	6.XXX «Теперь сходитесь», сама сцена	0,446
3	6.XXVI «Опершись на плотину, Ленский»	0,431
4	1.XVI «Уж темно: в санки он садится»	0,426
5	5.XLV «Но ей нельзя. Нельзя? Но что же?»	0,418

Модель переводит запрос и каждую строфу в точки одного пространства из 1024 измерений и ищет ближайшие. Первые три места заняли вызов, сама сцена и ожидание у плотины. Слова «поединок» нет ни в одной из них.

Посмотрите на косинусы: от 0,42 до 0,46. Такой поиск вернёт строфы на любой запрос, даже если ответа в романе нет, и по самим числам этого не понять. Качество векторной выдачи видно только на размеченной выборке.

Пространство смысла

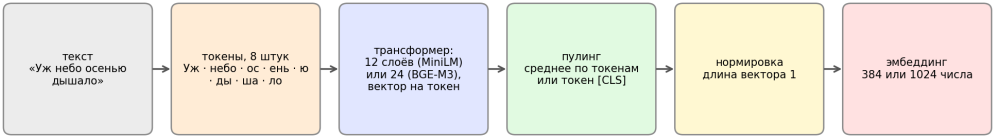


Мы закодировали 25 слов из пяти тем романа и спроецировали векторы на плоскость. Слова одной темы легли рядом: дуэль с поединком и выстрелом, письмо с посланием и запиской.

Косинус дуэли и поединка 0,76, зимы и снега 0,77. Индекс занятия 5 давал таким парам ноль. Словаря синонимов у модели нет, эту раскладку она получила при обучении.

Проекция на плоскость кое-что искажает: «секундант» и «сани» на рисунке почти совпадают, и в полном пространстве их косинус всего 0,46.

Путь текста в вектор

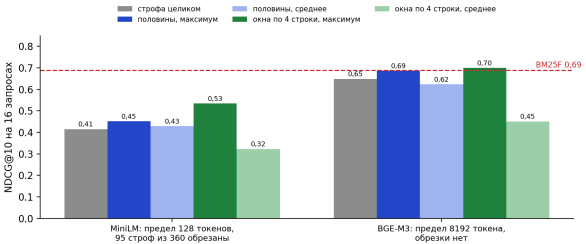


косинус двух нормированных векторов равен их скалярному произведению

Токенизатор режет строку на куски своего словаря, и редкие слова распадаются на части. Слои внимания пересчитывают вектор каждого токена с учётом соседей. Пулинг сворачивает векторы токенов в один вектор строки: MiniLM их усредняет, BGE-M3 берёт вектор первого служебного токена. После нормировки длина вектора равна единице, и косинус совпадает со скалярным произведением.

У каждой модели есть предел длины входа. У MiniLM это 128 токенов, и почти каждая четвёртая строфа в него не помещается: хвост строфы модель не видит. У BGE-M3 предел 8192 токена.

Длинные документы режут на куски

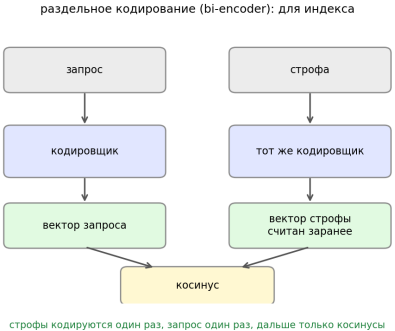


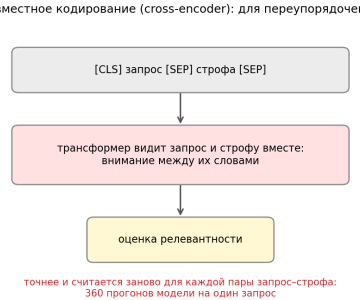
Длинный документ режут на куски и кодируют каждый кусок отдельно. Оценку документа можно взять по лучшему куску или по среднему.

Мы нарезали строфы на окна по четыре строки. MiniLM поднялась с 0,415 до 0,534: хвосты строф перестали теряться. BGE-M3 обрезки не знает и всё равно выросла до 0,700, сравнявшись со словами. Вектор окна говорит об одном, вектор целой строфы смешивает четырнадцать строк о разном.

Среднее по окнам качество портит, у BGE-M3 до 0,451. Запрос обычно отвечает одному месту документа.

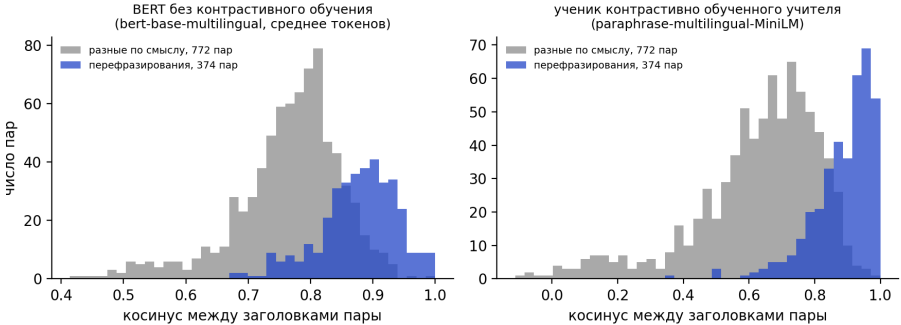
Раздельное и совместное кодирование





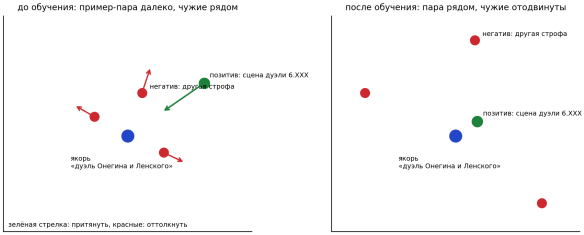
При раздельном кодировании векторы документов считаются заранее и один раз. На каждый запрос модель запускается один раз, дальше считаются косинусы. При совместном кодировании запрос и документ подаются в модель вместе. Оценка получается точнее, и модель приходится запускать на каждую пару: миллион прогонов на миллион документов. Поэтому раздельное кодирование отбирает сотню кандидатов, совместное их переупорядочивает. Переупорядочение разберём в лекции 8.

Почему языковой модели мало



Модель BERT училась угадывать пропущенные слова. Если усреднить её векторы токенов, перефразирования из ParaPhraser получают косинус в среднем 0,88, пары заголовков разного смысла 0,77, и ниже 0,6 опускаются только 42 непохожие пары из 772. Векторы всех текстов собраны в узкий конус, и модели любые два текста кажутся похожими. Это называют анизотропией. Справа модель, которая прошла контрастивное обучение через своего учителя: непохожие пары у неё разъехались до 0,63.

Учить на контрасте: якорь, позитив, негатив

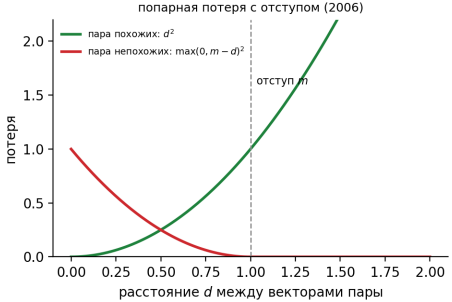


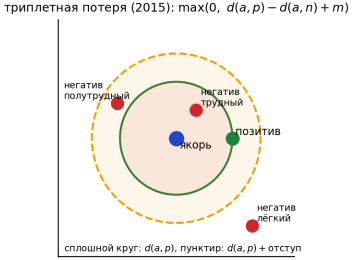
Модель учат на тройках текстов. Якорь задаёт текст, для которого учится вектор. Позитив должен оказаться рядом с якорем, негативы дальше позитива. В ParaPhraser такую тройку дают заголовки, косинусы посчитаны обученной моделью MiniLM:

роль	заголовок	косинус
якорь	Лавров опроверг данные о содействии освобождению американцев в ДНР	1
позитив	Лавров опроверг данные о помощи в освобождении задержанных в ДНР американцев	0,93
трудный негатив	Лавров назвал нарушением обязательств прибытие военных США на Украину	0,73
лёгкий негатив	ЦБ отозвал лицензию у двух московских банков	0,27

Признаки, по которым «содействие освобождению» совпадает с «помощью в освобождении» и отличается от «прибытия военных США», модель находит сама на миллионах таких троек.

Попарная и триплетная потери





Попарная потеря (Хадселл, Чопра, Лекун, 2006) тянет похожую пару к нулевому расстоянию и отталкивает непохожую до заданного отступа m. Ей нужна одна шкала расстояний для всех пар, и в этом её слабость. Триплетная потеря (FaceNet, 2015) требует только порядка: позитив должен быть ближе негатива хотя бы на отступ, $L = \max(0,\ d(a,p) - d(a,n) + m)$.

Пусть расстояние до позитива 0,5, отступ 0,3. Трудный негатив на расстоянии 0,4 даёт потерю 0,4, полутрудный на 0,7 даёт 0,1, лёгкий на 1,2 даёт ноль. Учит не всякий негатив, и случайные негативы почти все лёгкие.

InfoNCE: выбрать позитив среди многих

$$L = -\log \frac{\exp\big(s(q, d^+)/\tau\big)}{\exp\big(s(q, d^+)/\tau\big) + \sum_{j=1}^{n} \exp\big(s(q, d_j^-)/\tau\big)}$$

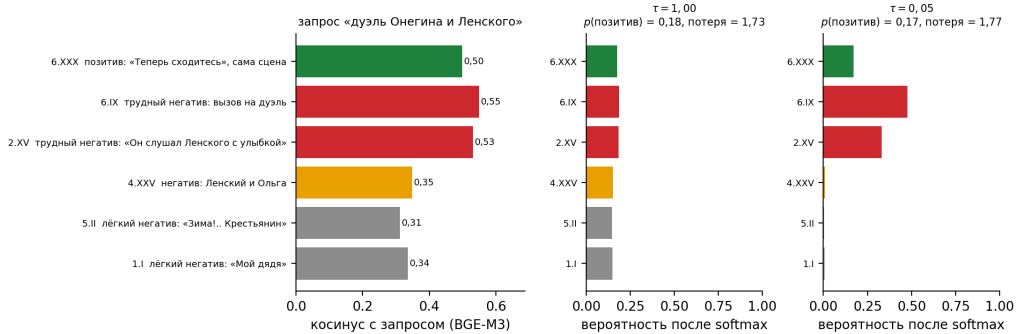
Современные модели учат потерей, которая сравнивает позитив d^+ сразу со многими негативами d_j^-.

Косинусы s якоря с кандидатами делятся на температуру τ и превращаются функцией softmax в вероятности. Потеря равна минус логарифму вероятности позитива.

По сути это обычная классификация: модель учится угадывать, какой из $n + 1$ кандидатов подходит к якорю. Числитель тянет позитив к якорю, знаменатель отталкивает все негативы сразу.

Потерю называют InfoNCE (ван ден Оорд и соавторы, 2018). В библиотеке sentence-transformers она называется MultipleNegativesRankingLoss (Хендерсон и соавторы, 2017), в работе SimCLR NT-Xent.

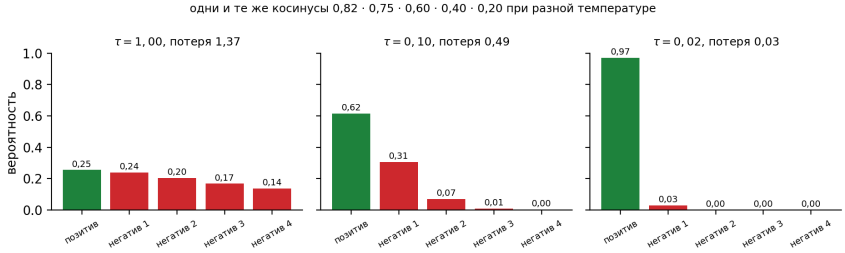
InfoNCE на «Онегине»



Запрос «дуэль Онегина и Ленского». Позитив, сама сцена «Теперь сходитесь», получил у BGE-M3 косинус 0,499. Выше него стоят вызов на дуэль, 0,550, и строфа «Он слушал Ленского с улыбкой», 0,532, где есть имена героев и нет дуэли. При $\tau = 0{,}05$ позитиву достаётся вероятность 0,17, потеря 1,77. Обучение на этом примере потянуло бы сцену к запросу и оттолкнуло оба трудных негатива.

Строфа «Опершись на плотину, Ленский» получила ещё больше, 0,563. Взять её негативом нельзя: в выборке она размечена как часть ответа.

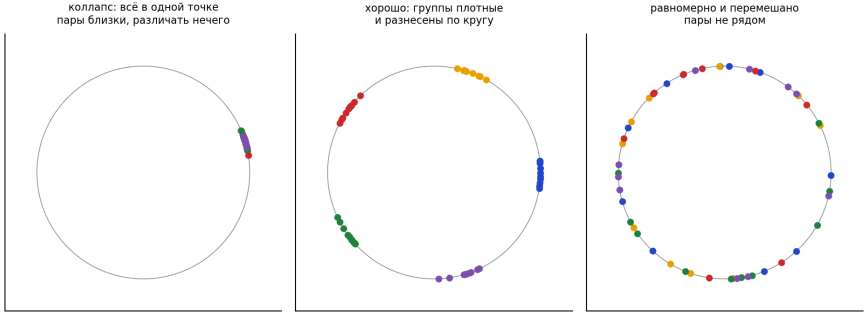
Температура



Косинусы лежат между -1 и 1, и без деления на температуру разница между кандидатами слишком мала для обучения. На рисунке пять условных косинусов: при $\tau = 1$ позитив получает вероятность 0,25, при 0,1 уже 0,62, при 0,02 почти всю.

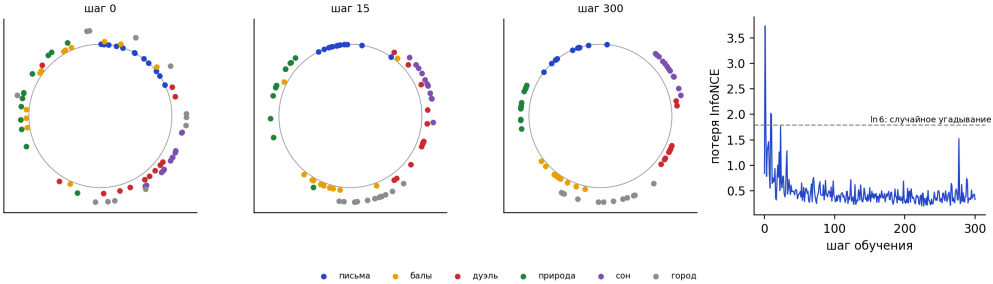
На «Онегине», где позитив стоит третьим, вероятность позитива равна 0,18 при $\tau = 1$, 0,22 при 0,1 и 0,17 при 0,05. Малая температура сначала отнимает вес у лёгких негативов, потом отдаёт его трудным. Если среди трудных негативов окажется неразмеченный правильный ответ, модель будет отталкивать его изо всех сил. Обычно берут τ от 0,01 до 0,1, в sentence-transformers 0,05.

Что даёт обучение: выравнивание и равномерность



Ван и Изола (2020) описали хорошее пространство двумя свойствами. Выравнивание держит положительные пары рядом, его обеспечивает числитель InfoNCE. Равномерность разносит векторы всех текстов по сфере, её обеспечивает знаменатель. Если оставить одно выравнивание, все тексты соберутся в одну точку, и различать станет нечего. Узкий конус BERT как раз и нарушает равномерность.

Обучение на игрушечном примере



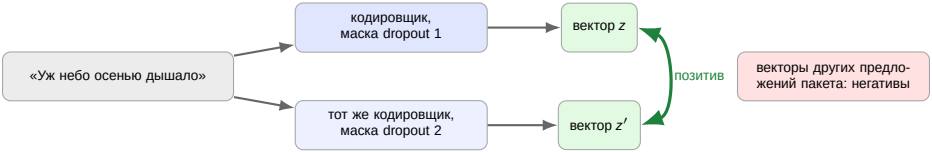
Шесть групп точек в двадцатимерном пространстве линейно отображаются на окружность, и модель учится потерей InfoNCE при $\tau = 0{,}2$. При случайных весах часть групп перемешана, и потеря 2,2 даже выше уровня случайного угадывания, пунктира на графике. К трёхсотому шагу шесть плотных дуг разошлись по окружности, и потеря упала до 0,44. Обучение занимает секунды, это шаг 5 блокнота. Настоящая модель учится так же, с трансформером на месте линейного отображения и сотнями миллионов пар на месте шести групп.

Где взять пары для обучения

источник	что служит позитивом	модели и наборы
логический вывод (NLI)	следствие из предложения, противоречие служит трудным негативом	SimCSE с разметкой, 2021
поисковые журналы	запрос и отрывок текста с ответом	MS MARCO (запросы Bing), Natural Questions (запросы Google), DPR
перефразирования	два заголовка об одном событии	ParaPhraser, модели paraphrase-*
слабые пары из сети	заголовок и текст, вопрос и ответ на форуме	E5, 2022: сотни миллионов пар
научные ссылки	статья и статья, которую она цитирует	SPECTER, 2020
научные аннотации	аннотации одной статьи, статьи близких рубрик OECD	SciRus-tiny: 12 млн аннотаций eLibrary
переводы	предложение и его перевод	LaBSE
сам текст	два прогона одного предложения с разным dropout	SimCSE без разметки, 2021
изображение и подпись	картинка и подпись к ней	CLIP, 2021
модель-учитель	вектор учителя для оригинала	многоязычные paraphrase-*, 2020

Чему модель научится, определяют её пары. MiniLM, которой мы кодировали «Онегин», училась на коротких предложениях и переводах, и длинная стихотворная строфа для неё непривычна. SciRus-tiny училась на научных аннотациях и хорошо сравнивает именно их.

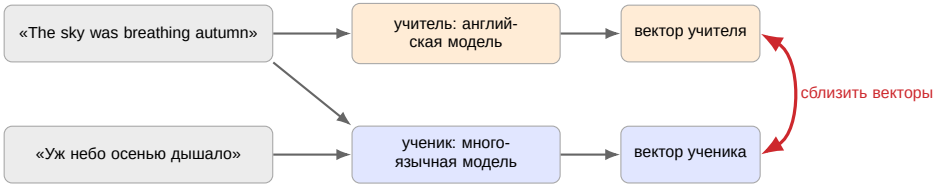
Пары без разметки: SimCSE



Если размеченных пар нет, позитив можно получить из самого предложения. Dropout при каждом прогоне выключает случайную часть нейронов, и одно предложение, прогнанное через модель дважды, даёт два немного разных вектора. Они и служат позитивной парой, негативами служат другие предложения пакета (Гао, Яо, Чен, 2021).

Так учат модели для языков и областей, где размеченных пар нет. Вариант SimCSE с разметкой берёт позитивом следствие из данных NLI и трудным негативом противоречие.

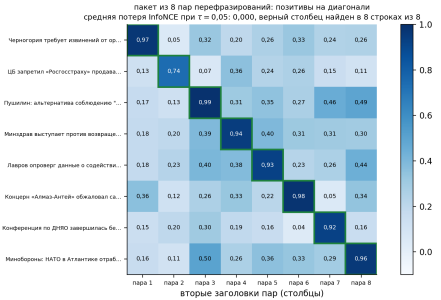
Пары от модели-учителя: дистилляция



Многоязычную модель можно получить из хорошей английской. Пары здесь даёт параллельный корпус: английское предложение и его перевод. Ученик учится выдавать для перевода и для оригинала тот же вектор, что учитель выдаёт для оригинала (Реймерс, Гуревич, 2020).

Так получена MiniLM, которой мы кодировали «Онегин». Учитель знал короткие английские перефразирования, и ученик унаследовал это знание вместе с его пределами.

Негативы из пакета

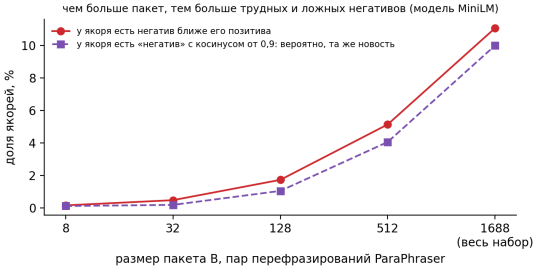


Самые дешёвые негативы лежат прямо в пакете. В пакете B пар «якорь и позитив», и для каждого якоря негативами служат позитивы остальных пар.

Вся матрица косинусов считается одним умножением, правильные пары стоят на диагонали, и потеря требует, чтобы в каждой строке диагональ была больше остальных клеток. На восьми парах ParaPhraser диагональ от 0,74 до 0,99, остальные клетки от 0,04 до 0,50.

Чем больше пакет, тем больше бесплатных негативов. SimCLR учили на пакетах до 8192 примеров, CLIP на пакетах из 32 768 пар. Негативы из пакета в основном лёгкие: заголовок о Лаврове почти наверняка далёк от заголовка о ценах на нефть.

В большом пакете появляются ложные негативы



В ParaPhraser одна новость часто входит в несколько пар, и 30 якорей встречают среди чужих позитивов свой собственный заголовок. Чем больше пакет, тем чаще у якоря находится «негатив» с косинусом от 0,9: на всём наборе так у десяти процентов якорей.

Якорь «NYT: российские хакеры получили доступ к электронной переписке Обамы» и его позитив «Хакеры из России прочитали переписку Обамы» дают 0,92. В тот же пакет попал «СМИ: Российские хакеры получили доступ к переписке Обамы» с косинусом 0,97. Это та же новость, и потеря потребует оттолкнуть её сильнее позитива.

Повторы убирают до обучения или собирают пакеты без повторяющихся текстов.

Трудные негативы: откуда их берут

Тонким различиям учат трудные негативы, то есть тексты, похожие на запрос и не отвечающие на него. Источников у них три.

поиск по словам

Работа DPR (Карпухин и соавторы, 2020) брала негативы из первых мест выдачи BM25. На «Онегине» поиск по словам ставит первыми на запрос о дуэли ожидание у плотины, вызов и строфу «Он слушал Ленского с улыбкой».

выдача самой модели

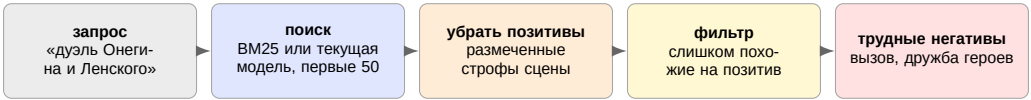
Работа ANCE (Сюн и соавторы, 2021) периодически ищет соседей запроса текущей моделью и берёт среди них неправильные. Модель учится на собственных ошибках.

разметка

В ParaPhraser 3735 пар размечены как близкие по смыслу без полного совпадения. Это готовые трудные негативы для перефразирований.

Поиск по словам занятия 5 оказывается поставщиком обучающих примеров для векторной модели, и два канала помогают друг другу уже при обучении.

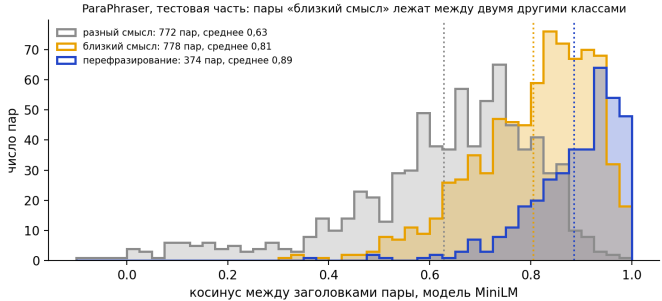
Ложные негативы и как их отсеивают



Первая строфа выдачи на запрос о дуэли, «Опершись на плотину, Ленский», в выборке размечена как часть ответа. Если взять её негативом, модель научится отталкивать правильный ответ. Такой негатив называют ложным.

В реальных данных разметка неполна, и ложный негатив выглядит как обычный трудный. Поэтому кандидатов чистят в два шага: сначала убирают всё, что размечено как ответ, потом отбрасывают кандидатов, слишком похожих на позитив, или проверяют их более точной моделью, например совместным кодировщиком.

Трудные негативы в разметке ParaPhraser



Пары класса «близкий смысл» лежат между перефразированиями и парами разного смысла: средние косинусы 0,89, 0,81 и 0,63. Самые похожие из них модель от перефразирований не отличает:

косинус	заголовок 1	заголовок 2
0,996	Более 15 ливийских солдат получили ранения в боях в городе Бенгази	Более 15 ливийских солдат получили ранения в ходе боев в Бенгази
0,992	ОБСЕ: закон о декоммунизации - угроза свободе слова на Украине	ОБСЕ: Законы о декоммунизации на Украине угрожают свободе слова

Граница между классами здесь проходит по решению разметчика, и негативы из разметки тоже проверяют.

Что модель умеет и чего ждёт на входе

Сами мы модели не обучаем. Из того, как их учат, следуют правила для того, кто берёт готовую модель.

1. Модель хорошо сравнивает тексты, похожие на её обучающие пары. Новости и перефразирования не учат ни поэзии, ни формулам.
2. Модель учили на определённой длине входа. Если текст длиннее, его хвост пропадает, и длинные документы режут на куски.
3. Модель учили на определённой форме входа. Модели E5 ждут перед запросом слово `query:`, перед документом `passage:`, научной модели подают название и аннотацию так, как сказано в её карточке. Без нужной формы векторы портятся, и при этом код работает без всякой ошибки.

Поэтому первое, что читают в карточке модели, это предел длины и форма входа. Ещё два следствия касаются того, чего модель не различает и как читать величину косинуса.

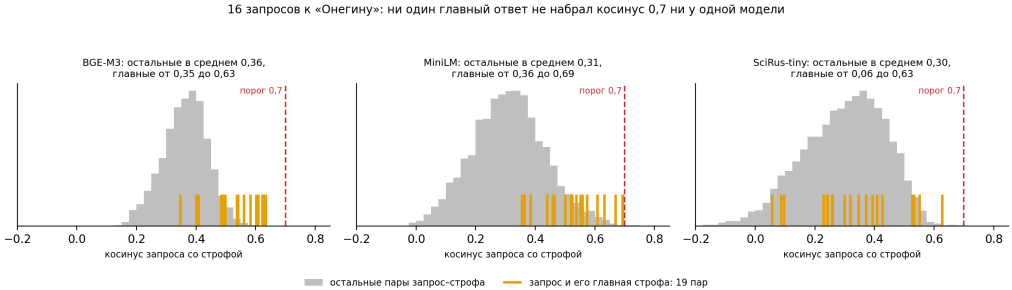
Что вектор не различает

Обучение на перефразированиях сближает тексты об одном событии, и текст об этом же событии с другим числом для модели тоже почти перефразирование. В ParaPhraser из 3354 пар, которые люди разметили как разные по смыслу, 56 получают у MiniLM косинус от 0,9.

косинус	заголовок 1	заголовок 2	различие
0,98	В Непале произошло землетрясение магнитудой 6,7	В Непале произошло мощное землетрясение магнитудой 6,8	число
0,98	Землетрясение магнитудой 5,1 произошло на севере Филиппин	Землетрясение магнитудой 5,1 произошло на юге Филиппин	место
0,95	Египет объявил турецкого посла персоной нон грата	Турция объявила египетского посла персоной нон грата	кто кого
0,95	Саакашвили обвинил Киев в отсутствии политической воли	Саакашвили опроверг свои слова об отсутствии у Киева политической воли	действие обращено

На положении о рецензировании пункт 9.1 разрешает повторную подачу статьи «не ранее чем через шесть месяцев». Та же фраза с условием «не позднее» получает с ним косинус 0,99, и отрицание «из организации авторов» и «не из организации авторов» тоже даёт 0,75. Векторный поиск находит текст о нужном событии, тот ли в нём факт, проверяют слова, правила и граф.

Порог косинуса не переносится



Соблазнительно считать релевантным всё, что набрало косинус выше 0,7. У шестнадцати запросов к «Онегину» девятнадцать главных строф, и ни одна не набрала 0,7 ни у одной из трёх моделей. У BGE-M3 две случайные строфы в среднем даже ближе друг к другу, 0,544, чем запрос к своей главной строфе, 0,531. На парах заголовков тот же порог выглядел бы разумным. Шкала зависит от модели и от вида пары, и порог, если он нужен, подбирают по своей размеченной выборке.

Готовые модели

модель	размерность	длина входа	чему учили
SBERT, 2019	768	128	первый кодировщик предложений из BERT, данные NLI
paraphrase-multilingual-MiniLM	384	128	дистилляция от английского учителя на переводах
E5, 2022	384–1024	512	сотни миллионов слабых пар из сети, префиксы `query:` и `passage:`
BGE-M3, 2024	1024	8192	больше ста языков, большие пакеты, трудные негативы
SciBERT, 2019	768	512	языковая модель на научных статьях без контрастивного обучения
SPECTER, 2020	768	512	SciBERT, дообученный по графу цитирования
SciRus-tiny	312	2048	научные аннотации eLibrary, лаборатория МГУ

SciBERT и модели под именем MathBERT учились только угадывать слова. Для поиска их векторы так же плохи, как векторы BERT, и служат лишь основой для контрастивного дообучения.

Как выбрать модель

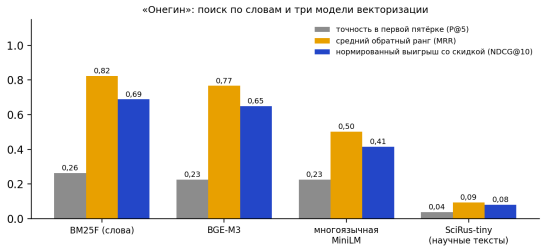
Модель выбирают по языку и области, по длине документов и по скорости. Скорость различается сильно: 360 строф BGE-M3 кодировала 113 секунд, MiniLM 7,6 секунды. На миллионе таких документов это три с половиной дня против нескольких часов.

Таблицы MTEB и ruMTEB показывают средний результат по чужим задачам. Решает своя выборка: две-три модели прогоняют на запросах из занятия 5 и сравнивают метрики.

пример SciRus-tiny

На научных аннотациях SciRus-tiny хороша. На «Онегине» её нормированный выигрыш 0,08, на корпусах курса 0,58 и 0,44, последнее место из четырёх каналов. Стихи, нормы и формулировки теорем лежат далеко от того, на чём её учили.

Три модели против поиска по словам

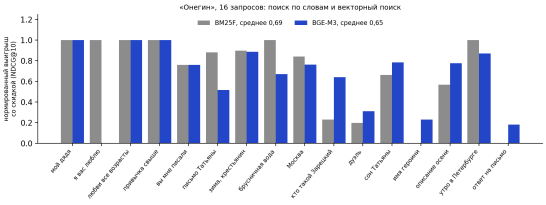


Шестнадцать запросов занятия 5, нормированный выигрыш со скидкой: поиск по словам 0,689, BGE-M3 0,649, MiniLM 0,415, SciRus-tiny 0,081.

Целыми строфами ни одна модель слова не обогнала. BGE-M3 близка к ним, MiniLM училась на коротких предложениях, SciRus-tiny на стихах почти ничего не находит.

Среднее прячет главное, и его стоит разложить по запросам.

Где векторы сильнее слов и где слабее

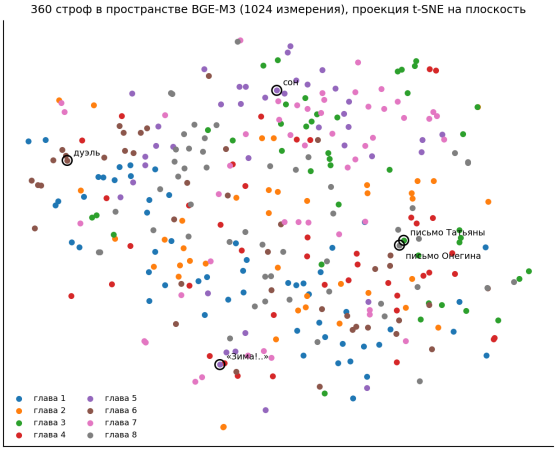


Векторы выигрывают на вопросах о персонажах, событиях и смысле своими словами: «кто такой Зарецкий» 0,23 у слов и 0,64 у BGE-M3, «описание осени» 0,57 и 0,78.

Точную цитату векторы теряют. На «Я вас люблю, к чему лукавить» нужная строфа у BGE-M3 стоит на 43-м месте, слова ставят её первой. Вектор цитаты оказывается вектором разговора о любви.

Простое слияние двух выдач дало 0,637, хуже каждого канала. Соединять каналы с умом будем в лекции 8.

Карта строф

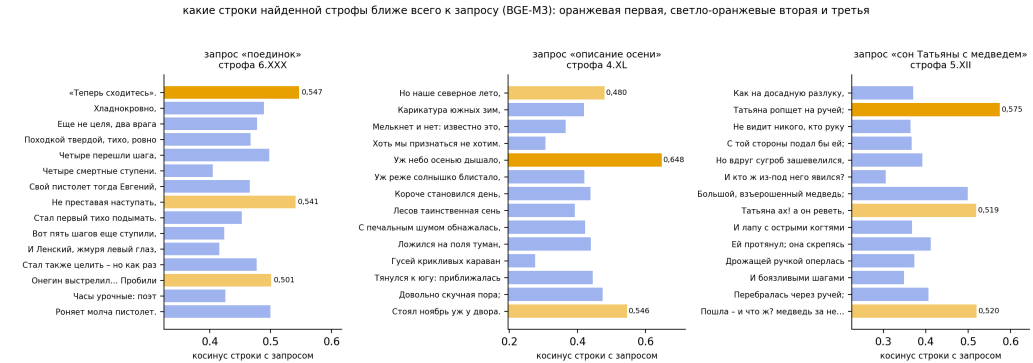


360 строф в пространстве BGE-M3, сжатые на плоскость методом t-SNE, цвет означает главу. Главы перемешаны: модель группирует строфы по содержанию.

Письмо Татьяны из третьей главы и письмо Онегина из восьмой лежат рядом. В полном пространстве их косинус 0,734 при среднем 0,544 для двух случайных строф, и письма оказываются ближайшими соседями друг друга.

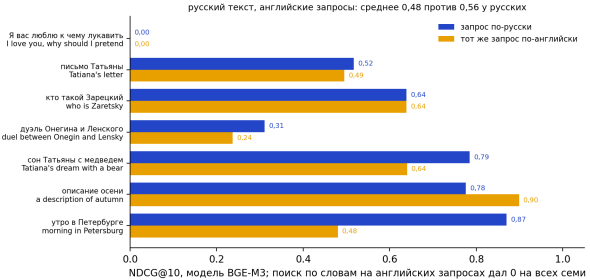
Карта искажает расстояния. На неё можно смотреть, мерить по ней нельзя.

Какая строка нашлась



Векторный поиск возвращает строфу целиком и не показывает, чем она подошла. Объяснение строится так: каждая строка найденной строфы кодируется той же моделью и сравнивается с запросом. «Поединок» указывает на «Теперь сходитесь», «описание осени» на «Уж небо осенью дышало» и следом на «Стоял ноябрь уж у двора». У запроса о сне Татьяны с медведем лучшие строки содержат Татьяну или медведя. Такую строку агент кладёт в пометку «найдено по смыслу», и её легко сверить с текстом.

Запрос по-английски к русскому тексту

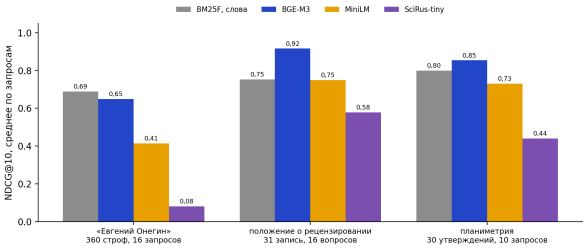


Среди обучающих пар BGE-M3 есть переводы, и для неё перевод оказывается разновидностью перефразирования.

Семь английских запросов дают в среднем 0,48, их русские версии 0,56. «A description of autumn» даже обгоняет русский запрос и ставит «Уж небо осенью дышало» первой.

Поиск по словам на английских запросах даёт ноль: общие слова у романа с ними находятся только во французских вкраплениях.

На корпусах курса векторы сильнее слов



Корпуса проектов устроены иначе, чем «Онегин»: короткие записи, вопросы своими словами, цитат нет.

На положении о рецензировании BGE-M3 даёт 0,916 при 0,753 у слов, и во всех шестнадцати вопросах первым в её выдаче стоит правильный ответ. На планиметрии 0,854 при 0,799.

Из 26 запросов векторы выигрывают 16, на шести идут вровень, на четырёх немного уступают.

Вопрос о сроке рецензирования

Вопрос «Сколько недель даётся на подготовку отзыва». Ответ дан в пункте 6.6 «Срок рецензирования» (R66): «Рецензия представляется в течение 21 дня с момента назначения рецензента». Общих слов у вопроса и пункта нет.

место	поиск по словам	BGE-M3
1	пункт 8.2 «Использование ИИ-инструментов» (R82)	**пункт 6.6 «Срок рецензирования» (R66)**
2	раздел 1 «Область применения» (S01)	пункт 9.1 «Повторная подача» (R91)
3	термин «ИИ-инструмент» (T11)	пункт 6.4 «Ответ на замечания» (R64)

У вопроса с корпусом одна общая основа, «подготовк», и поиск по словам возвращает три записи, где она встречается. BGE-M3 ставит пункт 6.6 первым: в пространстве модели «сколько недель» оказалось рядом со сроком в днях, «отзыв» рядом с рецензией. Этот вопрос поиск по словам не находил с первого занятия.

Перефразировка и формула

перефразировка

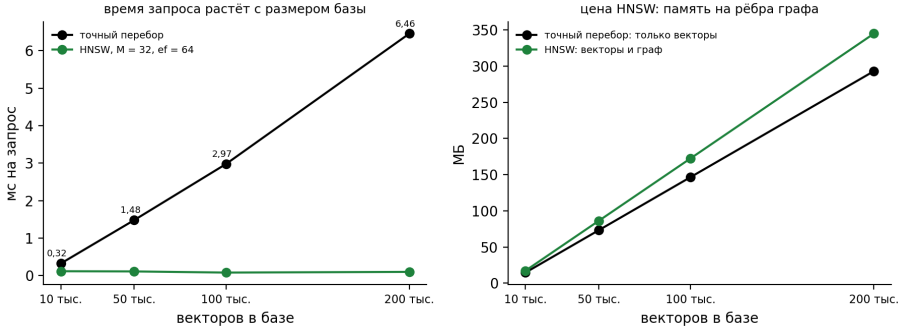
Вопрос «Сколько мнений экспертов нужно для решения по статье». Слов «мнение» и «эксперт» в положении нет. Поиск по словам цепляется за «решение» и «статью» и получает 0,39. BGE-M3 ставит первыми пункт 6.5 «Принятие решения» и пункт 6.1 «Число рецензий» и получает 1,0.

формула

Запрос $a^2 + b^2 = c^2$ к планиметрии. Поиск по словам теоремы Пифагора не находит. BGE-M3 ставит первой формулу Герона, где тоже есть буквы a, b, c, второй теорему косинусов, теорему Пифагора только седьмой. Формулу модель сравнивает как строку символов.

Перефразировку векторы закрывают. Для формул нужен свой канал, который разбирает выражение и сравнивает его строение.

Цена точного поиска



Найти ближайшие векторы значит посчитать скалярное произведение запроса со всеми векторами базы и выбрать наибольшие. На десяти тысячах векторов размерности 384 точный перебор тратит треть миллисекунды на запрос, на двухстах тысячах шесть с половиной миллисекунд, и время растёт линейно с размером базы. Граф HNSW на тех же базах тратит около десятой доли миллисекунды. На миллиарде векторов перебор займёт десятки секунд на каждый запрос, поэтому большие базы ищут приближённо.

Приближённый поиск и две полноты

Слово «полнота» теперь означает две разные вещи. На занятии 5 полнота мерила, какую долю релевантных документов нашёл поиск. У приближённого поиска полнота мерит, какую долю истинных ближайших векторов нашёл индекс по сравнению с точным перебором.

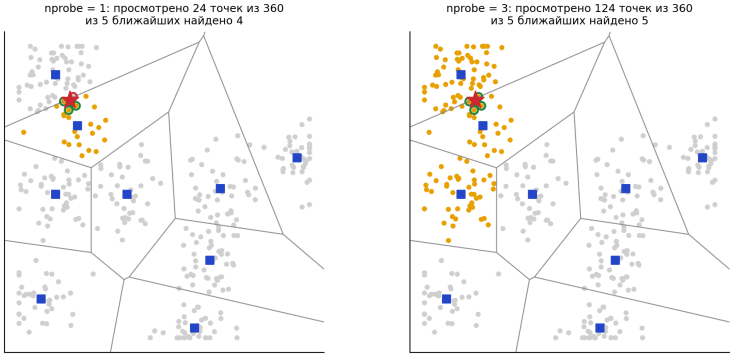
Индекс с полнотой 0,99 найдёт нерелевантные строфы, если плоха модель. Индекс отвечает за скорость, модель за смысл, и проверять нужно обоих.

Подходы к приближённому поиску:

семейство	идея	пример
деревья	делить пространство	Annoy
хеширование	похожие векторы в одну корзину	LSH
кластеры и сжатие	искать в ближних ячейках	IVF, PQ
графы	идти к цели по рёбрам	HNSW

Дальше разберём два последних.

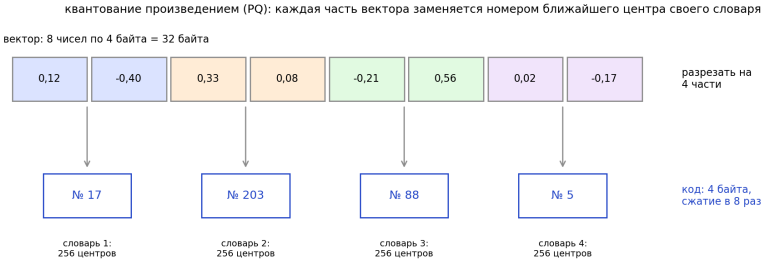
IVF: искать только в ближних кластерах



синие квадраты: центры кластеров, оранжевые точки: просмотренные ячейки, кружки: 5 истинных соседей (зелёный найден, красный потерян)

Метод *k* средних заранее делит базу на кластеры, и каждый вектор попадает в список ближайшего центра. Поиск просматривает только несколько кластеров, ближайших к запросу. Это тот же инвертированный список, что в индексе занятия 5, ключом в нём служит центр кластера. На заголовках со 128 кластерами один просмотренный кластер даёт полноту 0,53, шестнадцать кластеров 0,95. Слабое место видно на рисунке: запрос у границы ячейки теряет соседей, оказавшихся по другую сторону.

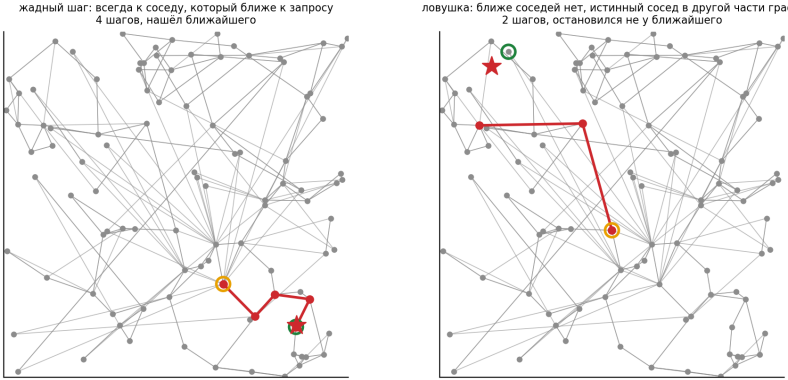
PQ: сжать векторы в десятки раз



Сжатие произведением, PQ, режет вектор на части и заменяет каждую часть номером ближайшего центра из своего словаря на 256 центров, то есть одним байтом. Вектор из 1536 байт становится кодом из 48 байт, и миллиард векторов занимает 48 ГБ при полутора терабайтах без сжатия. Искать можно, не распаковывая коды: для запроса один раз считаются таблицы расстояний до центров, и расстояние до кода складывается из нескольких чисел.

Платить приходится точностью: на заголовках полнота не выше 0,73. Сжатый индекс используют для отбора кандидатов и пересчитывают их точными векторами, так полнота поднимается до 0,93–0,95. Ещё грубее сжатие оставляет от каждой координаты знак: 128 байт на вектор BGE-M3, и на «Онегине» качество почти не меняется, 0,644 при 0,649.

Поиск по графу и его ловушка



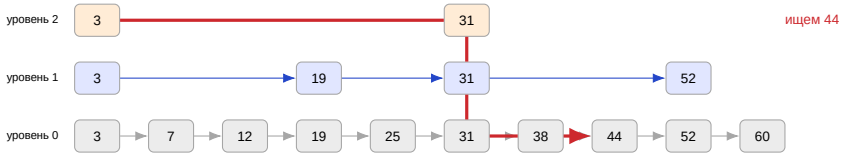
оранжевый кружок: точка входа, зелёный: истинный ближайший сосед, звезда: запрос; граф с малым числом связей, один слой

Третья идея: связать каждый вектор рёбрами с несколькими соседями и идти по графу. С текущей точки поиск переходит к соседу, который ближе к запросу, пока такой сосед есть. Слева поиск за четыре шага дошёл до цели. Справа он остановился: у текущей точки нет соседа ближе к запросу, и истинный ближайший сосед лежит в другой части графа. Граф из одних коротких рёбер плохо проходим на большие расстояния.

Две идеи, из которых вырос HNSW

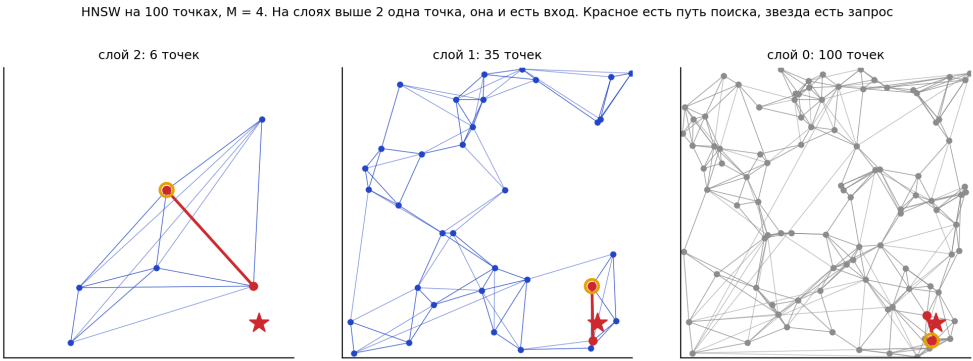
Первая идея пришла из теории сетей. Если у вершин есть ближние связи и немного дальних, путь между любыми двумя вершинами короткий (Уоттс, Строгац, 1998). Графы для поиска стали строить с рёбрами обоих видов: дальние рёбра быстро пересекают пространство, ближние точно подводят к цели.

Вторая идея пришла из структур данных. Список с пропусками (Пью, 1990) хранит отсортированные элементы на нескольких уровнях, каждый следующий уровень реже предыдущего. Поиск идёт большими прыжками сверху и спускается, когда следующий прыжок перелетел бы цель.



HNSW переносит список с пропусками с прямой на граф в многомерном пространстве.

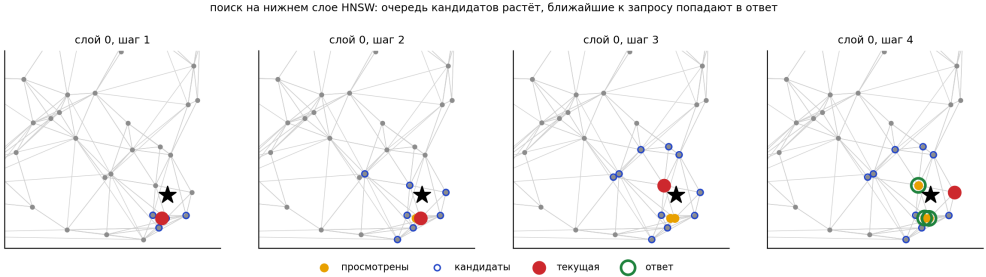
HNSW: слои графа



Нижний слой содержит все векторы, каждый следующий примерно в M раз реже, и рёбра на нём длиннее. Поиск входит на верхнем слое, жадно идёт к запросу и спускается в найденную точку на слой ниже. Верхние слои дают дальние переходы, нижний слой точный подход к цели.

Уровень точки выбирается случайно при вставке, и вероятность попасть на слой ℓ и выше равна $M^{-\ell}$. На 13 738 заголовках при $M = 16$ слои содержат 13 738, 829, 40 и 4 точки, каждый примерно в шестнадцать раз реже предыдущего.

Поиск и вставка



На нижнем слое поиск держит очередь из *efSearch* лучших кандидатов. Он берёт ближайшего непросмотренного кандидата, просматривает его соседей, лучших ставит в очередь и останавливается, когда новые кандидаты перестают улучшать очередь. Очередь помнит несколько путей сразу, и поиск не застревает в первом локальном минимуме. Вставка новой точки устроена так же: тот же поиск находит ей соседей на каждом её слое, и рёбра ставятся в обе стороны.

Как выбирать соседей при вставке



Простое правило берёт *M* ближайших кандидатов, и слева все три соседа оказались в одной кучке. Эвристика из статьи HNSW берёт кандидата, только если он ближе к новой точке, чем к уже выбранным соседям. Справа она взяла одного соседа из кучки и двух в других направлениях.

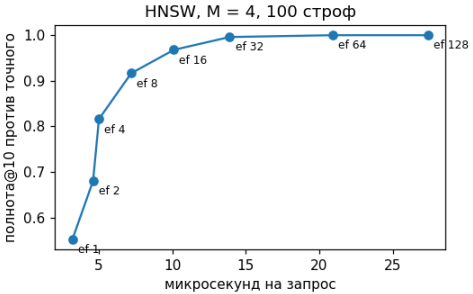
На учебном графе из 30 скоплений по 40 точек при одинаковом числе посчитанных расстояний простое правило находит 72 процента истинных соседей, эвристика 92 процента. Рёбра в разные стороны связывают скопления между собой.

Параметры HNSW

параметр	когда задаётся	что определяет	обычные значения
M	при построении	число соседей точки, на нижнем слое вдвое больше	8–64, часто 32
efConstruction	при построении	тщательность вставки, качество графа	40 по умолчанию в FAISS
efSearch	при каждом поиске	полноту и время поиска	16 по умолчанию, не меньше *k*

efSearch меняется без перестройки индекса, и на практике подбирают именно его. Время поиска растёт примерно как логарифм числа точек.

Мини-практика: HNSW на 100 строфах



Векторы BGE-M3 первых ста строф, FAISS HNSW с $M = 4$, каждая строфа служит запросом, ищутся десять соседей.

efSearch	полнота@10	мкс на запрос
1	0,554	3,2
4	0,816	5,0
16	0,967	10,1
32	0,995	13,9
128	0,999	27,4

Полнота 0,95 достигается при *efSearch* $= 16$, с 64 она равна 0,999 и дальше не растёт. Повторите это на ста векторах своего корпуса и запишите, при каком *efSearch* полнота доходит до 0,95 и почти до единицы и во сколько раз выросло время.

Библиотека FAISS

```
import faiss, numpy as np
X = np.load("data/emb_bgem3.npy").astype("float32")
faiss.normalize_L2(X)          # косинус = скалярное произведение

index = faiss.IndexFlatIP(X.shape[1])     # точный перебор
index.add(X)
D, I = index.search(q[None, :], 10)       # значения и номера

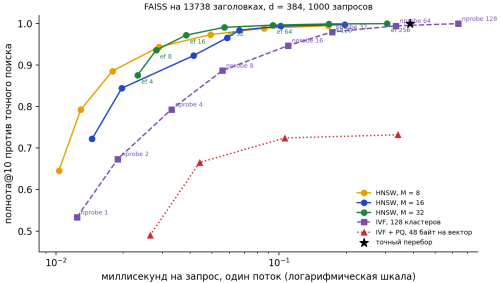
hnsw = faiss.IndexHNSWFlat(X.shape[1], 32,
                           faiss.METRIC_INNER_PRODUCT)
hnsw.add(X)
hnsw.hnsw.efSearch = 64                   # без перестройки

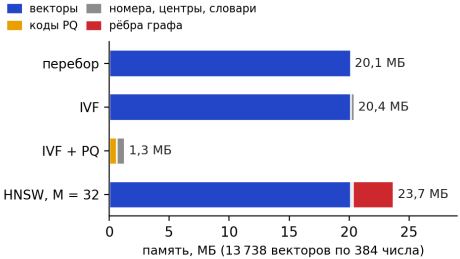
ivfpq = faiss.index_factory(X.shape[1], "IVF128,PQ64",
                            faiss.METRIC_INNER_PRODUCT)
ivfpq.train(X); ivfpq.add(X)
```

FAISS выпустила в 2017 году лаборатория Facebook AI Research. В ней собраны все индексы этой лекции, и перебор, IVF и PQ работают также на видеокартах. Milvus и OpenSearch строят индексы через FAISS, Qdrant, Weaviate и pgvector написали свои реализации HNSW.

Ошибаются обычно в трёх местах. Индексы хранят `float32`, и `normalize_L2` на массиве `float64` падает. Индексы с кластерами и сжатием нужно обучить вызовом `train` до `add`. Строка фабрики вроде `IVF128,PQ64` требует, чтобы размерность делилась на число частей PQ.

Четыре индекса на одних данных

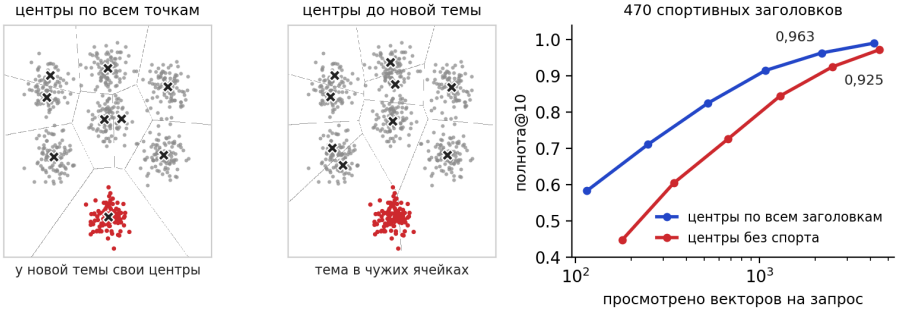




Заголовки ParaPhraser, модель MiniLM, 1000 запросов, один поток. Перебор тратит 0,39 мс на запрос. HNSW находит 99 процентов соседей за 0,057 мс, в семь раз быстрее, и его граф прибавляет к векторам 18 процентов памяти. IVF при той же полноте медленнее HNSW и прибавляет к векторам полтора процента.

Часто пишут, что HNSW занимает в 2–5 раз больше памяти, чем векторы. При $M = 32$ так бывает только у коротких векторов, до 64 чисел: рёбра весят одинаково при любой размерности, и у векторов из 1024 чисел граф добавляет 7 процентов.

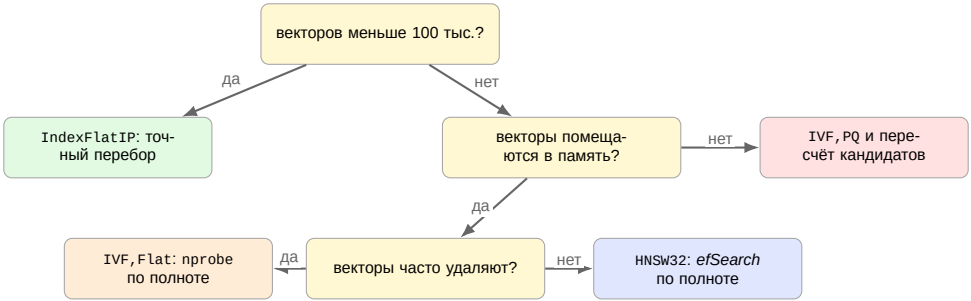
Новая тема в готовом индексе



Центры IVF обучают один раз, на данных, которые были в базе в момент обучения. Слева схема, справа опыт: центры обучили на заголовках без 470 спортивных и потом добавили в индекс все. Спорт разошёлся по чужим ячейкам, и при *nprobe* $= 16$ полнота для спортивных запросов упала с 0,963 до 0,925. Вернуть её удалось, удвоив *nprobe*. Запросы о прочих темах не пострадали. Поэтому при новых темах центры IVF обучают заново.

HNSW обучения не требует. Граф, в который спорт вставили после остальных заголовков, нашёл его соседей с полнотой 0,993 при *efSearch* $= 32$, граф, построенный заново, с полнотой 0,995.

Как выбрать индекс



В любой ветке параметр подбирают по полноте против точного перебора на нескольких сотнях запросов. Для проекта курса с корпусом в сотни утверждений хватает перебора.

Удаление векторов индексы переносят по-разному. Перебор удаляет и сдвигает номера: вектор 11 после удаления номеров 0 и 10 стал девятым. IVF удаляет и сохраняет номера. HNSW удалять не умеет, и удалённые отсекают фильтром при поиске. На заголовках с удалённой десятой частью в выдаче не осталось ни одного удалённого, полнота 0,996. Время от времени граф строят заново.

Поиск почти-дубликатов

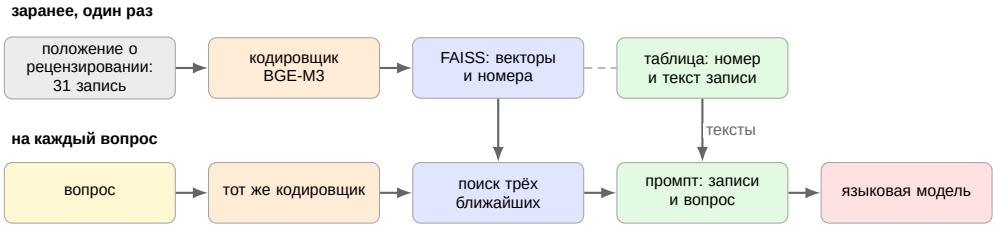


Индекс находит и дубликаты, если каждый вектор базы сделать запросом. HNSW по всем 14 738 заголовкам строится за 0,23 с, ближайшие соседи всех заголовков находятся ещё за 0,27 с в 16 потоков. Пар с косинусом от 0,9 нашлось 2383, большую часть люди разметили как перефразирование или близкий смысл.

В разметку не попала одна новость в двух изложениях, косинус 0,948: «В Турции за коррупцию арестованы сыновья трех министров» и «В Турции сыновей министров арестовали по обвинению в коррупции».

Пара с косинусом 0,950 описывает два разных сообщения: «Число жертв нового землетрясения в Непале возросло до 36 человек» и «…увеличилось до 42». Решение о дубликате принимают по словам и числам.

FAISS и языковая модель




```
Ответь на вопрос по положению о рецензировании,
опираясь только на записи ниже. Назови пункт.
Если ответа в записях нет, так и скажи.
[1] Пункт 6.6 «Срок рецензирования». Рецензия
    представляется в течение 21 дня с момента
    назначения рецензента.
[2] Пункт 9.1 «Повторная подача». ...
[3] Пункт 6.4 «Ответ на замечания». ...
Вопрос: Сколько недель даётся на подготовку отзыва?
```

FAISS отвечает только за поиск. Вопрос кодирует та же модель, что и записи. По номерам из выдачи тексты берутся из таблицы и вместе с вопросом идут в промпт. Ответ, 21 день по пункту 6.6, стоит в первой записи. Проверку ответа разберём на лекции 8.

Второй инструмент агента

```
{"name": "search_vectors",
 "description": "Поиск по смыслу (модель BGE-M3, косинус) по строфам «Евгения Онегина».
   На выборке из 16 запросов NDCG@10 = 0,65, полнота в первой десятке 0,68.
   Находит строфы по смыслу без общих слов: персонажи, события, описания.
   Плохо находит точные цитаты: для цитат вызывай search_words.
   Выдача не бывает пустой, низкий косинус не значит отсутствие ответа.",
 "parameters": {"query": "string", "k": "integer"}}

-> search_vectors("кто такой Зарецкий", 3)
<- 6.IV «Вперед, вперед, моя исторья!» 0,485 · 6.XXVII «Мой секундант? - сказал Евгений» 0,432
   · 6.XXVI «Опершись на плотину, Ленский» 0,425
```

На занятии 5 агент получил поиск по словам, и в описании инструмента стояло измеренное качество. Описание поиска по смыслу составлено так же: оно сообщает модели, что инструмент находит, чего не находит и насколько ему верить. По этим описаниям модель сама отправляет цитату «Я вас люблю, к чему лукавить» в поиск по словам, вопрос о Зарецком в поиск по смыслу. Каждая пометка в ответе, «найдено по словам» или «найдено по смыслу», сверяется с протоколом вызова. В лекции 9 выбор канала станет явной частью цикла агента.

Домашнее задание

Домашнее задание переносит лекцию на ваш корпус. Возьмите две модели векторизации: общую многоязычную и близкую к вашей области. Для каждой запишите размерность, предел входа и сколько документов длиннее предела. Решите, как резать длинные документы, и запишите решение в журнал.

Постройте векторный индекс и измерьте его на той же выборке и тем же скриптом метрик, что на занятии 5. Разберите запросы: где векторы лучше слов, где хуже и закрыты ли три провала занятия 5.

Сдаётся таблица «BM25 против векторного поиска» с выводом, который опирается на числа, и три запроса, которые не закрыли ни слова, ни векторы, с объяснением причины. Запросы о связях отметьте отдельно, ими займётся лекция 7.

Итоги

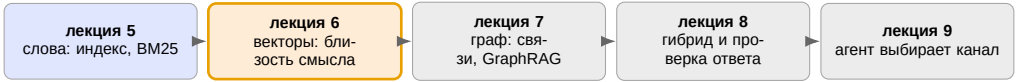
Плотный вектор сравнивает смысл, и «поединок» находит сцену дуэли без единого общего слова.

Модели векторизации получают контрастивным обучением. Всё в нём решают данные: пары задают, что модель будет считать близким, трудные негативы учат тонким различиям, ложные негативы учат ошибкам. Поэтому модель хорошо работает на том материале, на котором её учили.

На «Онегине» векторы выиграли на смысловых запросах и проиграли на цитатах, на положении о рецензировании они уверенно обогнали слова. Каналы дополняют друг друга, и в агенте нужны оба.

Приближённый поиск жертвует малой долей точности ради скорости. HNSW делает это, спускаясь по слоям графа, и *efSearch* задаёт компромисс между полнотой и временем.

К следующему занятию: графовый поиск



Запрос «ответ Онегина на письмо Татьяны» векторы подняли только с нуля до 0,18. Связь «ответ на» в тексте строф не записана, и найдёт её обход графа. Слова и векторы видят текст, граф видит связи между документами.

Литература

1. Hadsell R., Chopra S., LeCun Y. Dimensionality Reduction by Learning an Invariant Mapping. CVPR, 2006.
2. Schroff F., Kalenichenko D., Philbin J. FaceNet. CVPR, 2015.
3. van den Oord A., Li Y., Vinyals O. Representation Learning with Contrastive Predictive Coding. arXiv:1807.03748, 2018.
4. Henderson M. и др. Efficient Natural Language Response Suggestion for Smart Reply. arXiv:1705.00652, 2017.
5. Chen T. и др. SimCLR. ICML, 2020.
6. Wang T., Isola P. Alignment and Uniformity on the Hypersphere. ICML, 2020.
7. Gao T., Yao X., Chen D. SimCSE. EMNLP, 2021.
8. Radford A. и др. CLIP. ICML, 2021.
9. Reimers N., Gurevych I. Sentence-BERT. EMNLP, 2019. Статья недели.
10. Reimers N., Gurevych I. Multilingual Knowledge Distillation. EMNLP, 2020.
11. Karpukhin V. и др. Dense Passage Retrieval. EMNLP, 2020.
12. Xiong L. и др. ANCE. ICLR, 2021.
13. Wang L. и др. E5. arXiv:2212.03533, 2022.
14. Chen J. и др. BGE M3-Embedding. arXiv:2402.03216, 2024.
15. Beltagy I., Lo K., Cohan A. SciBERT. EMNLP, 2019.
16. Cohan A. и др. SPECTER. ACL, 2020.
17. Muennighoff N. и др. MTEB. EACL, 2023.
18. Jégou H., Douze M., Schmid C. Product Quantization. IEEE TPAMI, 2011.
19. Malkov Y., Yashunin D. HNSW. IEEE TPAMI, 2020 (arXiv:1603.09320).
20. Johnson J., Douze M., Jégou H. Billion-scale Similarity Search with GPUs. IEEE TBD, 7(3), 2021.
21. Douze M. и др. The Faiss Library. arXiv:2401.08281, 2024.
22. Pugh W. Skip Lists. CACM, 1990.
23. Watts D., Strogatz S. Small-World Networks. Nature, 1998.
24. ParaPhraser, `merionum/ru_paraphraser`, MIT. SciRus-tiny, `mlsa-iai-msu-lab/sci-rus-tiny`, MIT.